



首都师范大学

尚学尚师 求新求实

# 深度学习应用与工程实践

## 2. 机器学习

## 2. Machine Learning Types

李冰

副研究员，硕士生导师

交叉科学研究院

首都师范大学



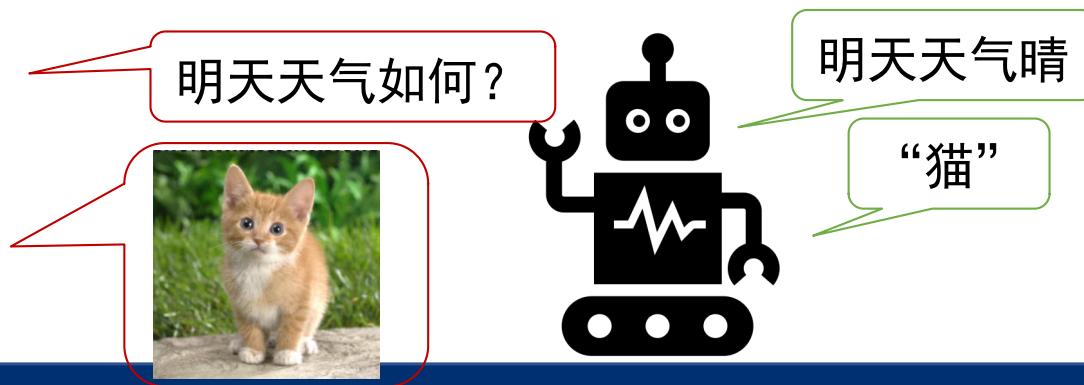
# 这节课

- 机器学习概述
  - 学习类型
- 深度学习
- 不同任务中深度学习的应用

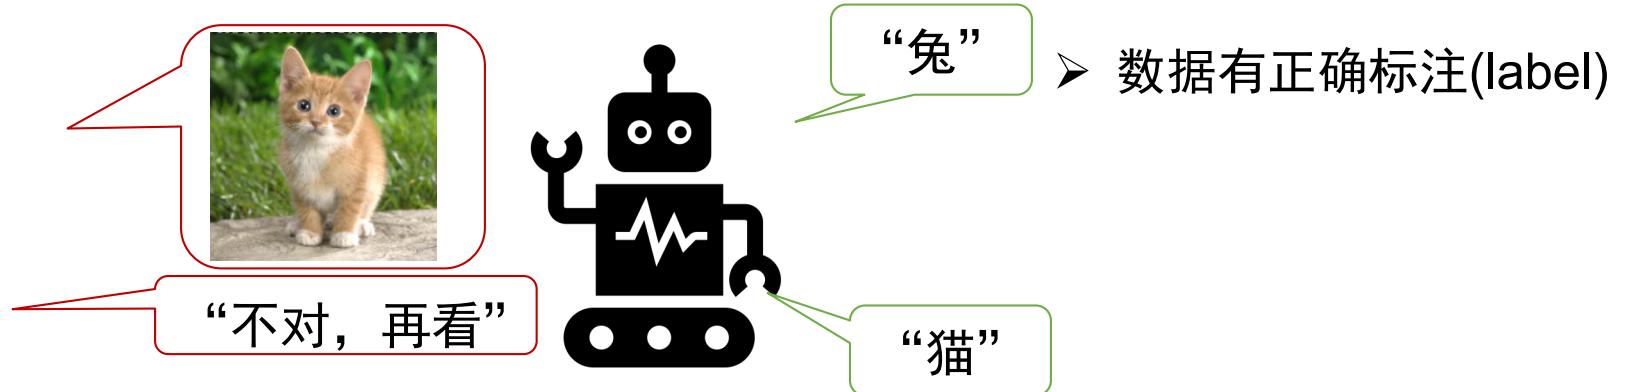


# 机器学习

- 机器学习是人工智能 (AI) 和计算机科学的分支
  - 使用数据和算法来模仿人类学习的方式。
- 深度学习是机器学习的子类。
  - 机器学习依赖于人工干预进行学习。
    - 人类专家确定一组特征，以了解数据输入之间的差异，通常需要更为结构化的数据以进行学习。
  - 深度学习
    - 自动执行数据中特征提取，消除人工干预，使用更大的数据集。



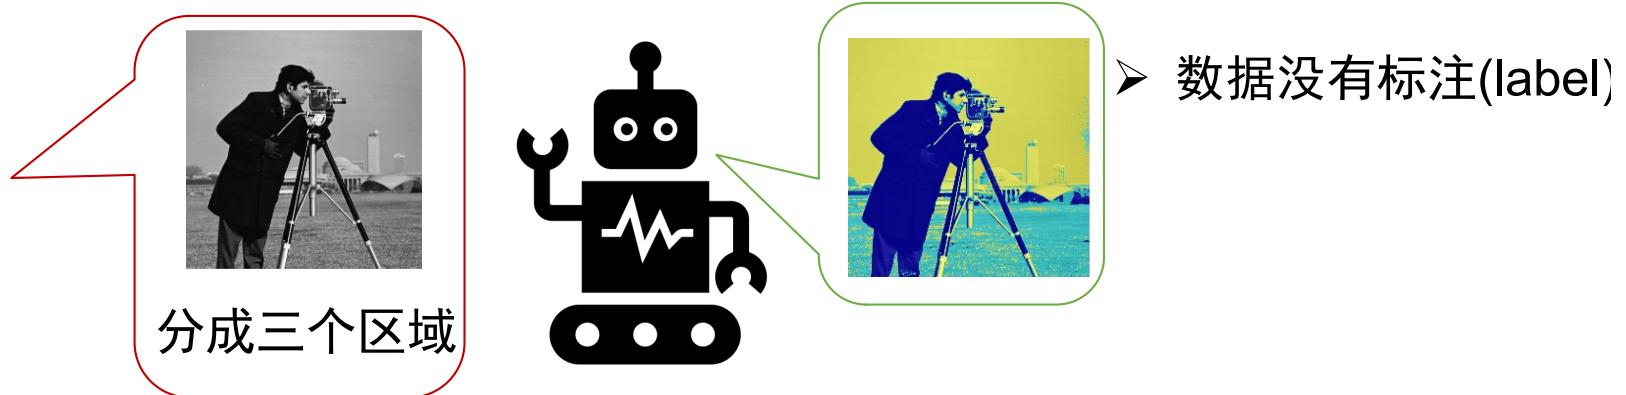
# 机器学习



## 监督式学习（也称为监督式机器学习）

- 使用标签化数据集训练算法，以准确分类数据或预测结果。
- 输入数据进入模型后，该方法会调整权重，直到模型拟合。
- 方法包括神经网络、朴素贝叶斯、线性回归、逻辑回归、随机森林、支持向量机 (SVM) 等。

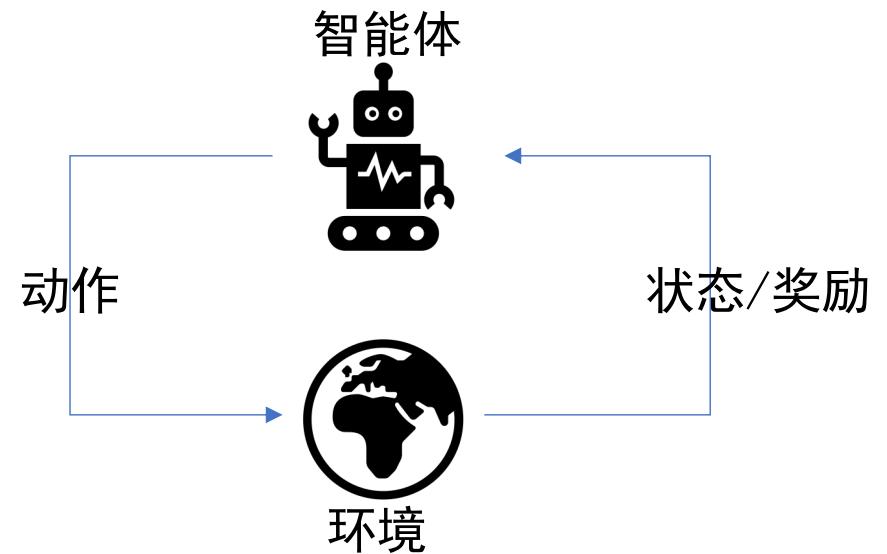
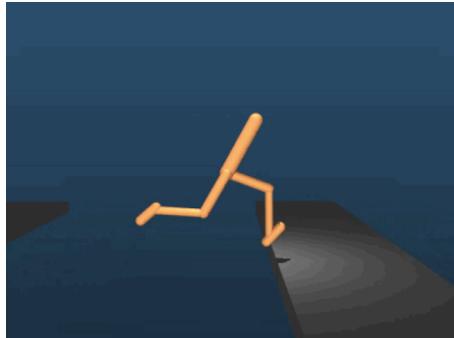
# 机器学习



## 非监督式学习

- 分析未标签化数据集并形成聚类，发现隐藏的模式或数据分组
- 发现信息的相似性和差异，无需人工干预。探索性数据分析、交叉销售策略、客户细分、图像和模式识别的理想解决方案。
- 该方法还通过降维过程，减少模型中特征的数量；主要成分分析(PCA)和奇异值分解(SVD)是两种常见的方法。
- 在无监督学习中使用的其他算法包括神经网络、k-平均值聚类、概率聚类方法等

# 机器学习

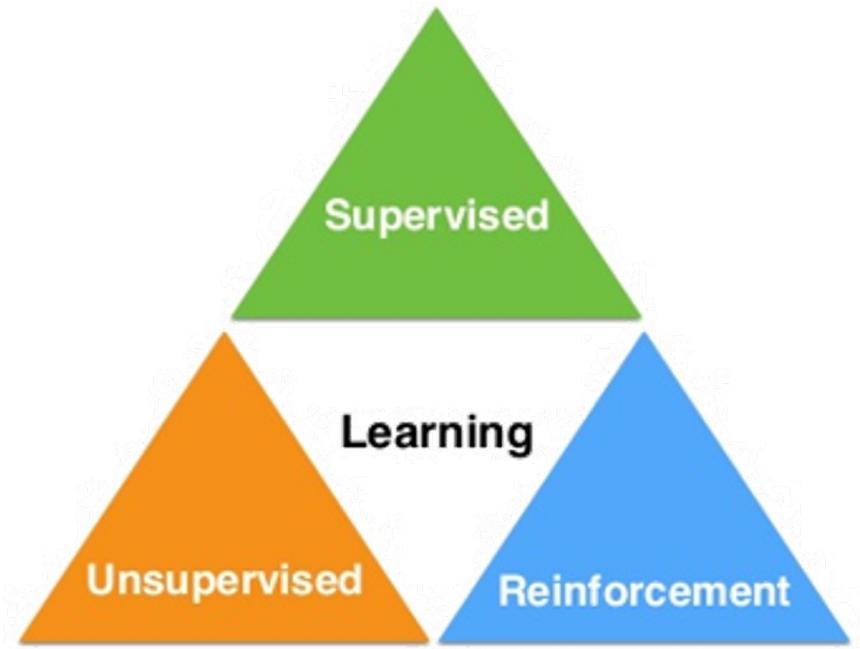


## 强化机器学习

- 通过不断试错进行学习，提出最佳建议或者最佳策略
- 策略性游戏，围棋、跳棋等

# 机器学习(Machine Learning)

- 一类从数据中自动分析获得规律，并利用规律对未知数据进行预测的算法。
- 监督学习：
  - $f(\text{输入}) \rightarrow \text{目标}$  (连续数值/离散量)
- 非监督学习：
  - $f(\text{输入}) \rightarrow \text{相似度/可能性}$
- 强化学习：
  - $f(\text{状态, 行为}) \rightarrow \text{价值}$



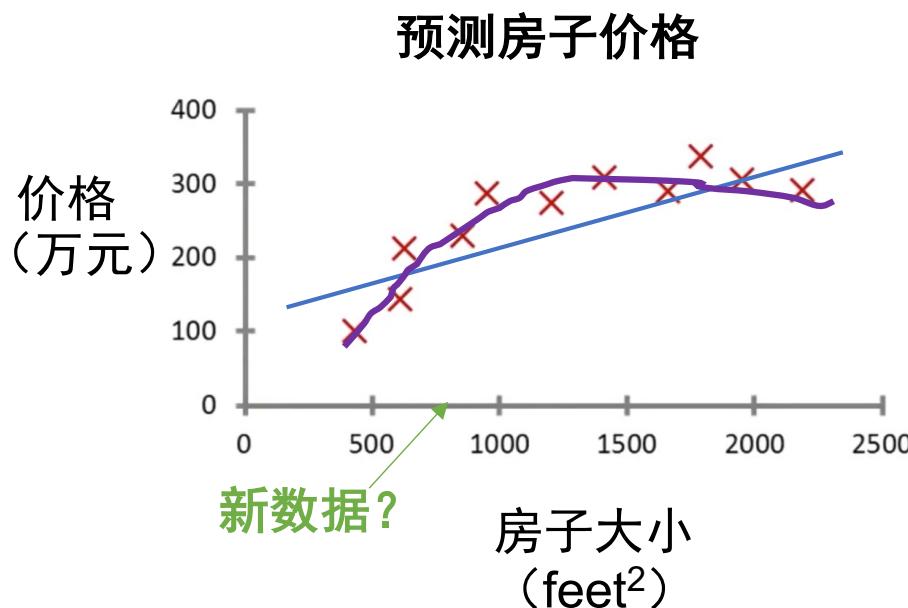
Credit: 台湾大学 李宏毅教授



# 监督学习 Supervised learning:

- 函数:  $f(\text{输入}) \rightarrow \text{目标}$ 
  - 连续具体数值: 回归 Regression
  - 离散: 分类 Classification

## 回归问题



数据: 房子面积, 房子价格  
目标: 有一定面积的房子, 价格是多少?

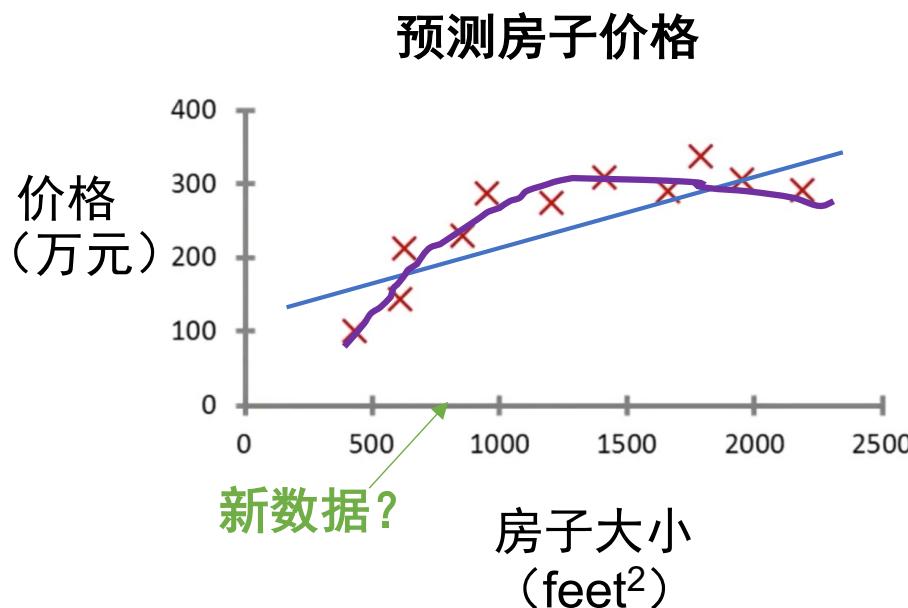
特征	目标值
2104	460
1416	232
1534	315
852	178



# 监督学习 Supervised learning:

- 函数:  $f(\text{输入}) \rightarrow \text{目标}$ 
  - 连续具体数值: 回归 Regression
  - 离散: 分类 Classification

## 回归问题



数据: 房子面积, 房子价格  
目标: 有一定面积的房子, 价格是多少?

特征	目标值
2104	460
1416	232
1534	315
852	178

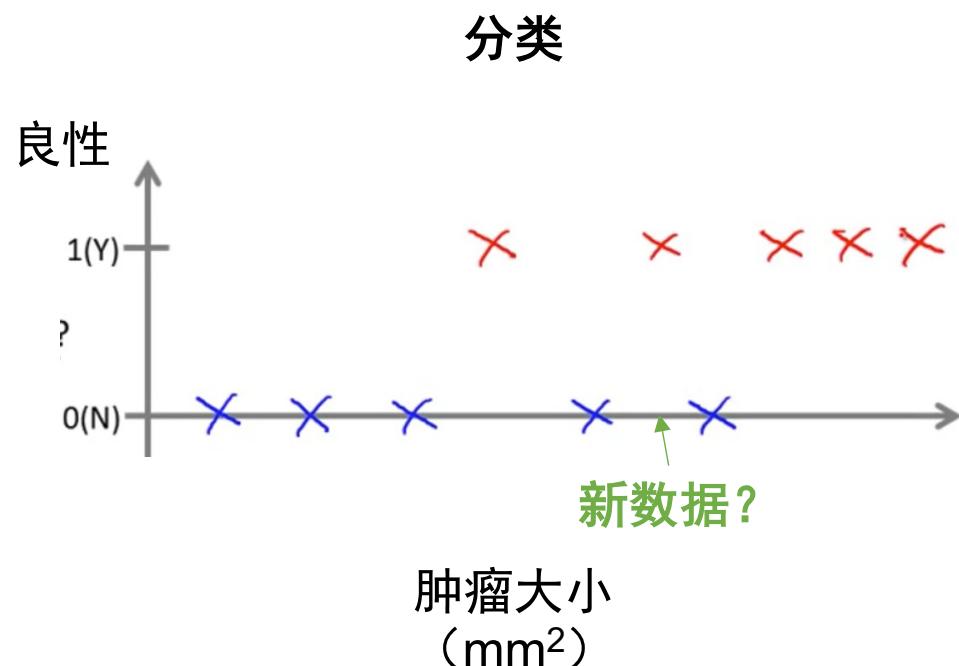
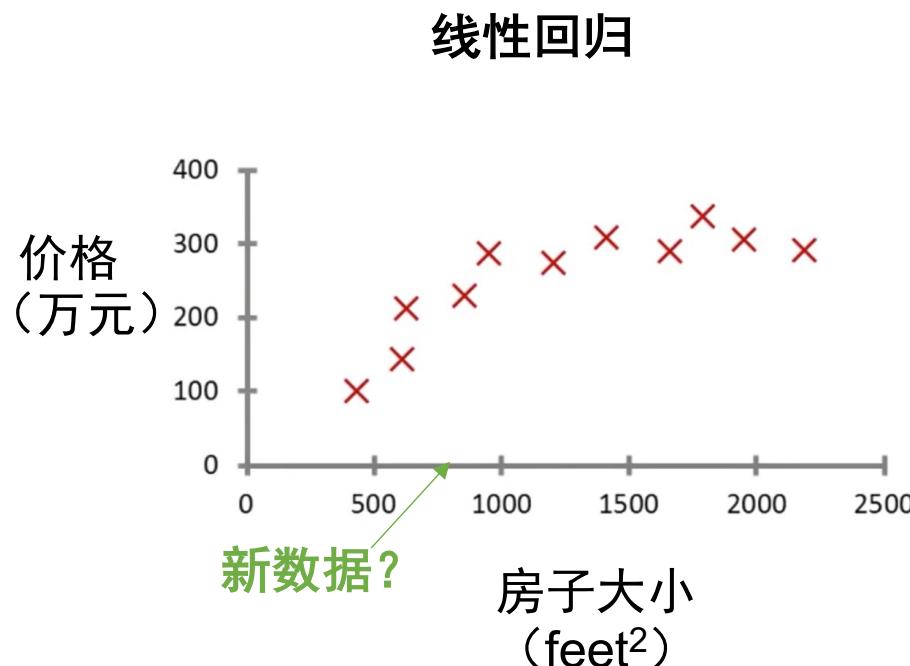
$$f(x) = wx + b$$

线性回归



# 监督学习 Supervised learning:

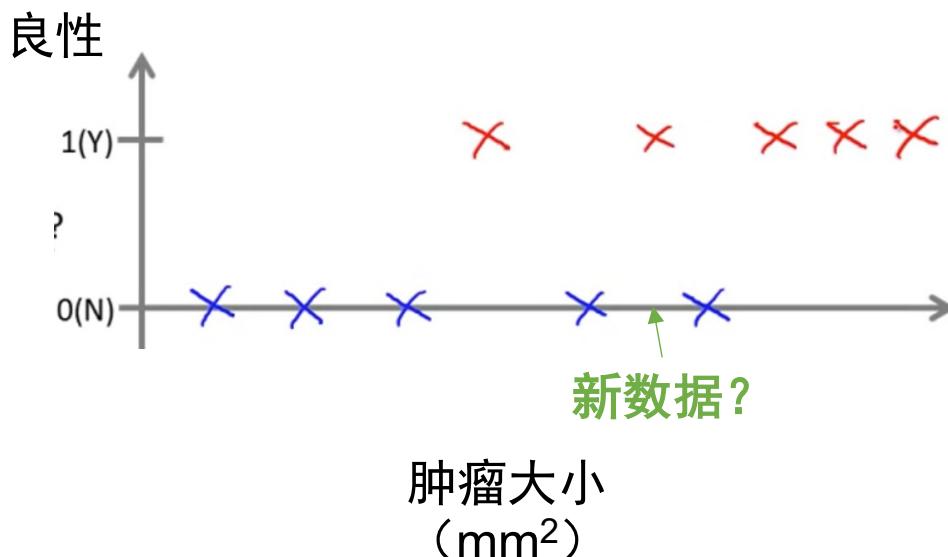
- 函数:  $f(\text{输入}) \rightarrow \text{目标}$ 
  - 连续具体数值: 回归 Regression
  - 离散: 分类 Classification



# 监督学习 Supervised learning:

- 函数:  $f(\text{输入}) \rightarrow \text{目标}$ 
  - 连续具体数值: 回归 Regression
  - 离散: 分类 Classification

肿瘤性质判断



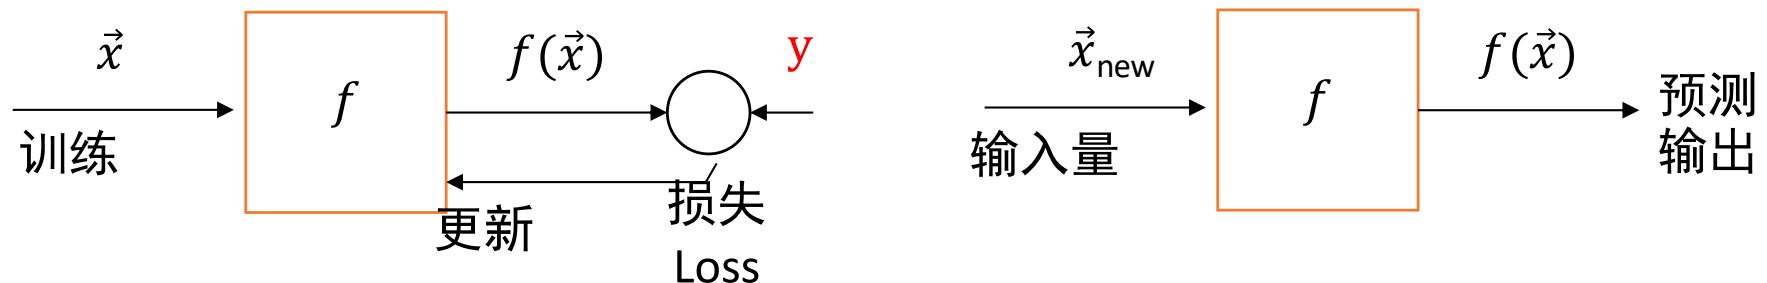
数据: 肿瘤大小, 恶性/良性  
目标: 肿瘤大小, 对肿瘤分类

特征	类别
2	0
3.2	1
4	0
1.2	0



# 回归 Regression

- 通过数据找出输入到输出的映射关系
- 利用找到的这个关系进行预测
- 输出是连续值。



训练数据集

$f(x)$ : 学习者

$x$ : 输入训练样本，样本有多个特征。

模型的输出 $y$ : 预测

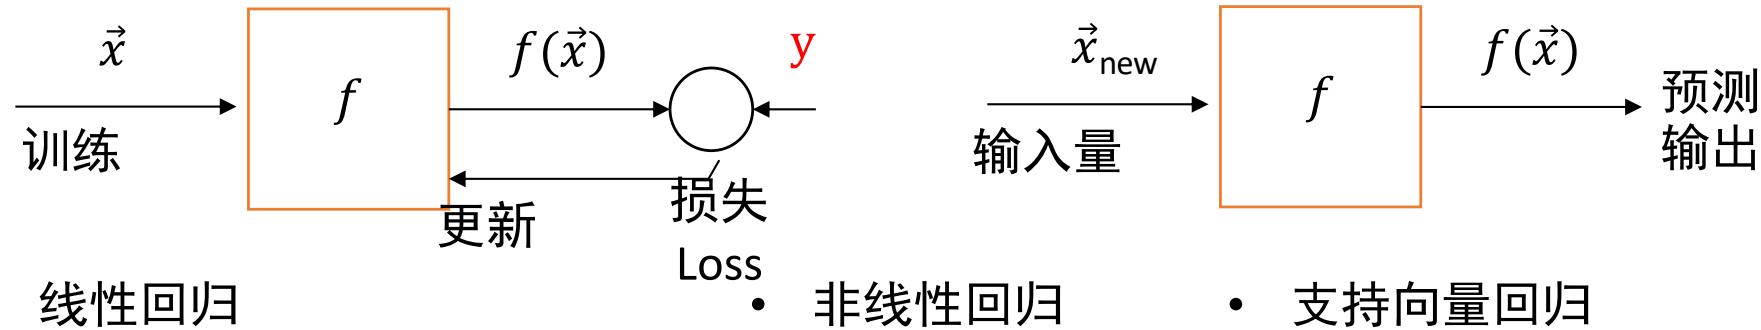
损失Loss: 预测值与真实值之间差异

新的数据 $x_{\text{new}}$   
学习者得到预测输出

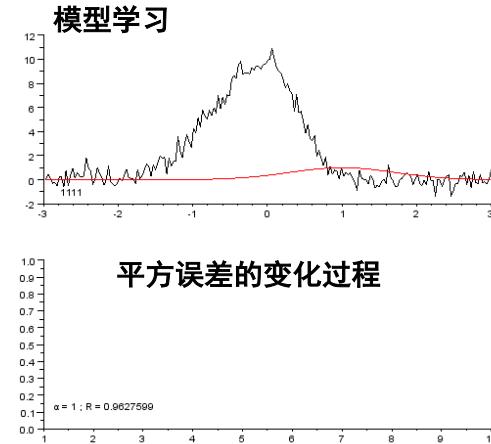
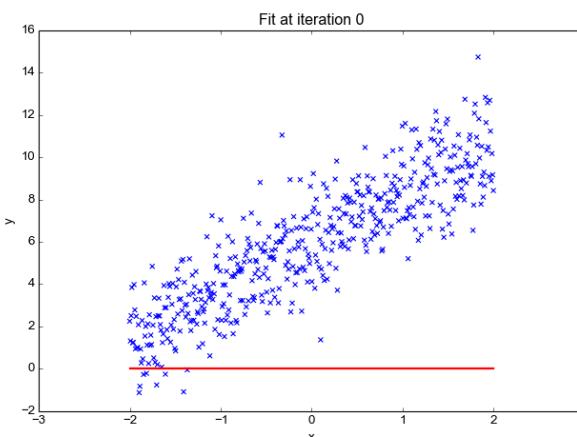


# 回归 Regression

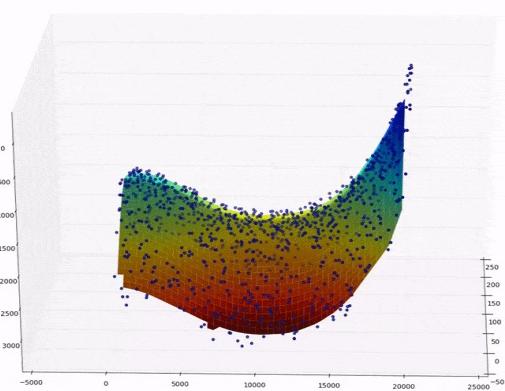
- 通过数据找出输入到输出的映射关系
- 利用找到的这个关系进行预测
- 输出是连续值。



- 线性回归



平方误差的变化过程



# 传统回归分析方法

- 线性回归
  - 学得一个通过属性进行线性组合进行预测的函数。

假设数据只有一个属性

$$\vec{x} = [x_1 \quad x_2 \quad \dots \quad x_n]$$

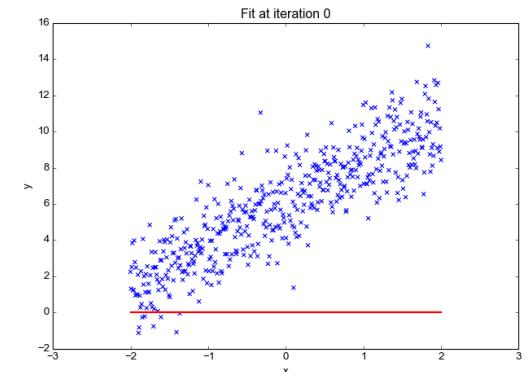
$$f(x_i) = w x_i \quad (i = 0 \dots n)$$

均方误差  $\omega = \operatorname{argmin}_{\omega} \sum_{\text{for all data}} \|\vec{x}\omega - y\|_2^2$

线性回归中，最小二乘法是试图找到一条曲线，使所有样本到直线上的欧式距离之和最小。

线性回归模型的“最小二乘”参数估计”

$$E = \sum_{\text{for all data}} \|\vec{x}\omega - y\|_2^2 \quad \frac{\partial E}{\partial w}$$

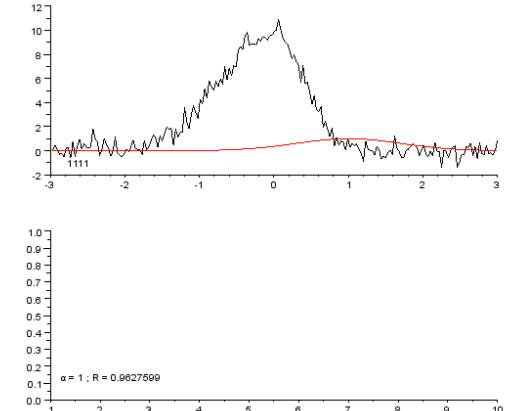


# 传统回归分析方法

- 多元线性回归
- 样本用多个属性描述

$$X = \begin{bmatrix} 1 & 1 & \dots & 1 \\ x_1 & x_2 & \dots & x_n \\ x_1^2 & x_2^2 & \dots & x_n^2 \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{p-1} & x_2^{p-1} & \dots & x_n^{p-1} \end{bmatrix}$$

$$\omega = \underset{\omega}{\operatorname{argmin}} \sum_{\text{for all data}} \|X^T \omega - y\|_2^2, (\omega \in \mathbb{R}^p)$$



当 $X^T X$ 为满秩矩阵或正定矩阵时

$$\omega = (X^T X)^{-1} X^T y$$

# 传统回归分析方法

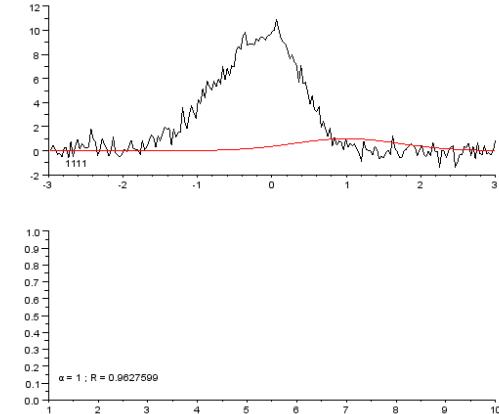
- 多元线性回归
- 样本用多个属性描述

$$X = \begin{bmatrix} 1 & 1 & \dots & 1 \\ x_1 & x_2 & \dots & x_n \\ x_1^2 & x_2^2 & \dots & x_n^2 \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{p-1} & x_2^{p-1} & \dots & x_n^{p-1} \end{bmatrix}$$

$$\omega = \underset{\omega}{\operatorname{argmin}} \sum_{\text{for all data}} \|X^T \omega - y\|_2^2, (\omega \in \mathbb{R}^p)$$

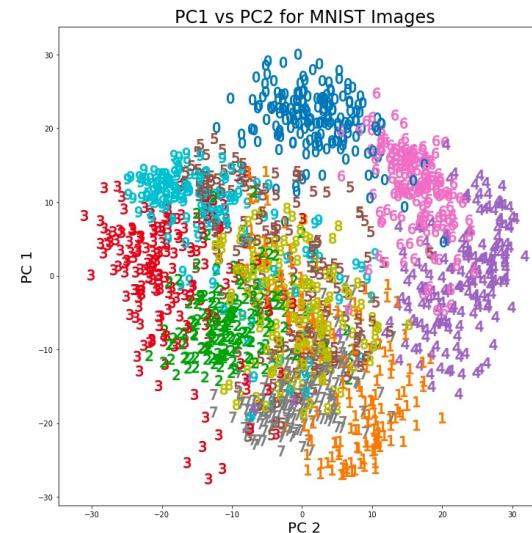
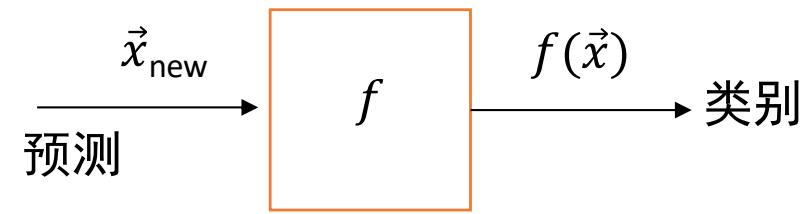
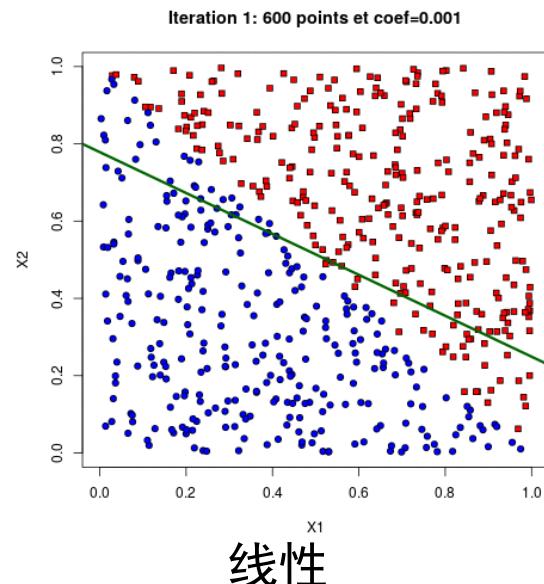
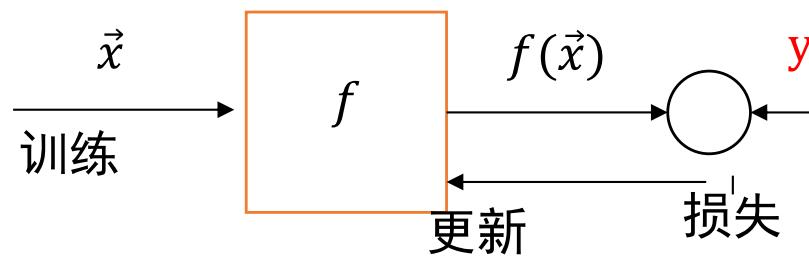
p : 数据点的个数, n : 数据维度。

- 当p>>n的时候, 不做任何其他假设或者限制的话, 学习问题基本上是没法进行的。
- p 越大, 通常会导致模型越复杂, 但是反过来 n 有很小, 于是就会出现很严重的 overfitting 问题。
- 如果p>n 的话, 矩阵X将会不是满秩的, 将会有无穷多个解。如果我们从所有可行解里随机选一个的话, 很可能并不是真正好的解。



# 分类

- 与回归问题相似。
- 唯一的区别：标签 $y$  和输出是离散的.

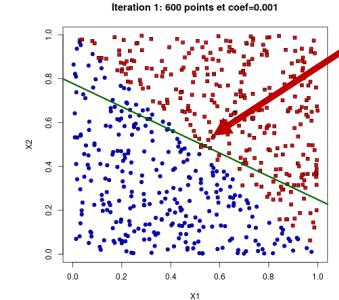


非线性、多分类



# 传统分类方法

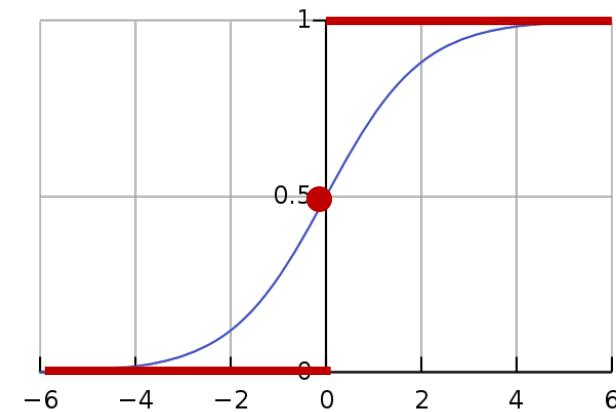
- 二分类任务，输出标记  $y \in \{0,1\}$ .
- Logistic回归 (对数几率回归)
  - 决策边界
  - 作用在n维空间，将不同样本分开的平面或曲面在对数几率回归中  $\vec{x}\omega = 0$



$$y = \begin{cases} 1, \omega X > 0 \\ 0.5 \quad \omega X = 0 \\ 0, \omega X < 0 \end{cases}$$

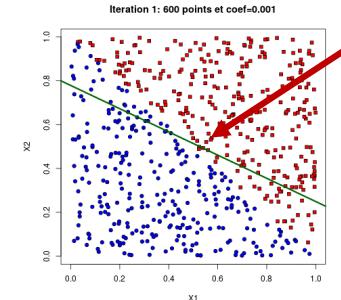
但，不可导，不连续

阶跃函数



# 传统分类方法

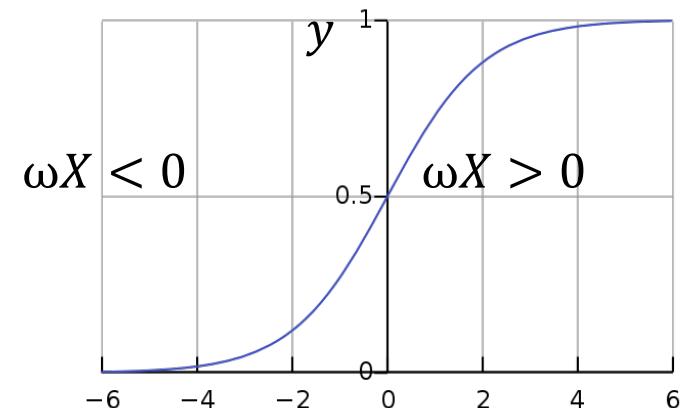
- 二分类任务，输出标记  $y \in \{0,1\}$ .
- Logistic回归 (对数几率回归)
  - 决策边界
  - 作用在n维空间，将不同样本分开的平面或曲面在对数几率回归中  $\vec{x}\omega = 0$



Sigmoid 函数  $y = \frac{1}{1 + e^{-\omega X}}$

$$\omega X = \ln\left(\frac{y}{1-y}\right)$$

$\frac{y}{1-y}$   $y$  表示 样本视为正例的可能性  
几率 (odds)  $1 - y$  表示样本为反例的可能性



# 传统分类方法

- Logistic回归 (对数几率回归)

Sigmoid 函数  $y = \frac{1}{1 + e^{-\omega X}}$

$$\omega X = \ln\left(\frac{y}{1-y}\right)$$

$y$  看作后验概率估计  $P(y = 1 | x)$

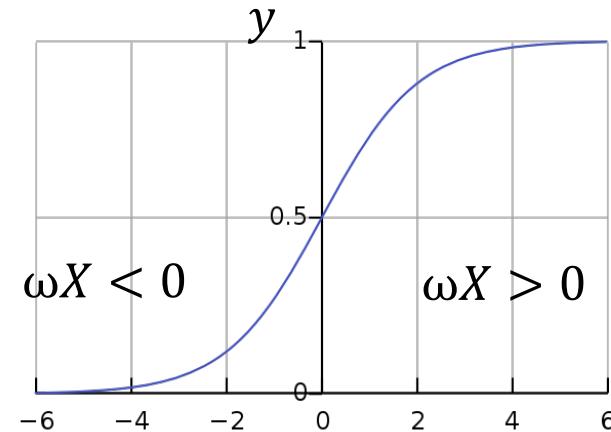
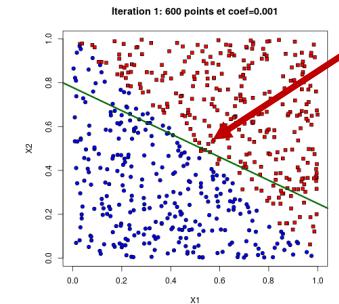
$$P(y = 1 | x) = \frac{1}{1 + e^{\omega X}}$$

$$P(y = 0 | x) = 1 - \frac{1}{1 + e^{\omega X}}$$

用极大似然法，来估计 $w$ 。

最大化对数似然

$$\sum_{i=1} \ln P(y_i | x_i; w)$$



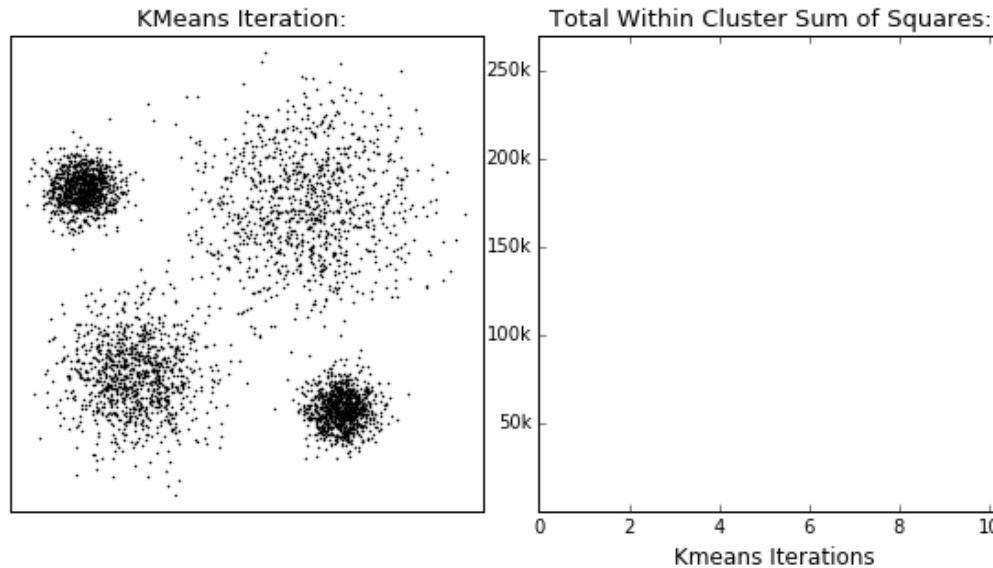
# 非监督学习

- 函数:  $f(\text{输入}) \rightarrow \text{相似性}$ 
  - 分布中采样;
  - 分布中去噪
  - 数据中的相关样本分类
    - 聚类算法



# 聚类

## K-均值算法



1. 随机地选择 $k$ 个对象，每个对象初始地代表了一个簇的中心；
2. 对剩余的每个对象，根据其与各簇中心的距离，将它赋给最近的簇；
3. 重新计算每个簇的平均值，更新为新的簇中心；
4. 不断重复2、3，直到收敛（每个Cluster中样本数目变化不大）

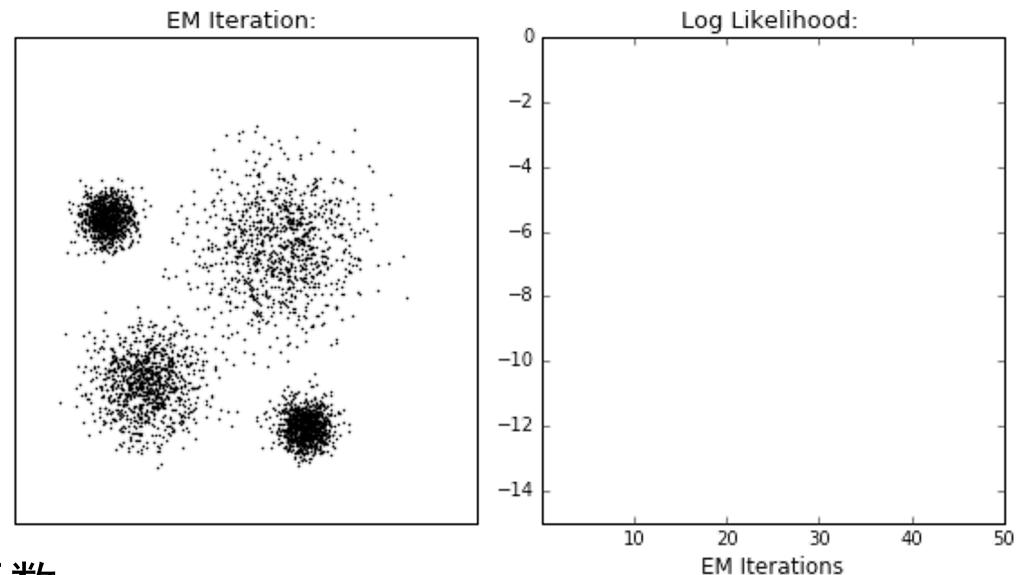


# 聚类

## 高斯混合模型

Gaussian mixture model (GMM)

$$p_{\mathcal{M}}(x) = \sum_{i=1}^k \alpha_i \cdot p(x | \mu_i, \Sigma_i)$$



高斯分布的n维随机向量x的概率密度函数

$$p(x) = \frac{1}{(2\pi)^{\frac{n}{2}} |\Sigma|^{\frac{1}{2}}} e^{-\frac{1}{2}(x-\mu)^T \Sigma^{-1} (x-\mu)}$$

$\mu$ 是n维均值向量  $\Sigma$ 是 $n \times n$ 的协方差矩阵，  $\mu_i$ 与 $\Sigma_i$ 是第*i*个高斯混合成分的参数，而 $\alpha_i > 0$ 为相应的“混合系数” (mixture coefficient),  $\sum_{i=1}^k \alpha_i = 1$

给定聚类簇数k，通过给定的数据集，以某一种参数估计的方法，推导出每一个混合成分的参数:均值向量 $\mu$ ,协方差矩阵 $\Sigma$ 和混合系数 $\alpha$   
每一个多元高斯分布成分即对应于聚类后的一个簇。

# 聚类

## 高斯混合模型

Gaussian mixture model (GMM)

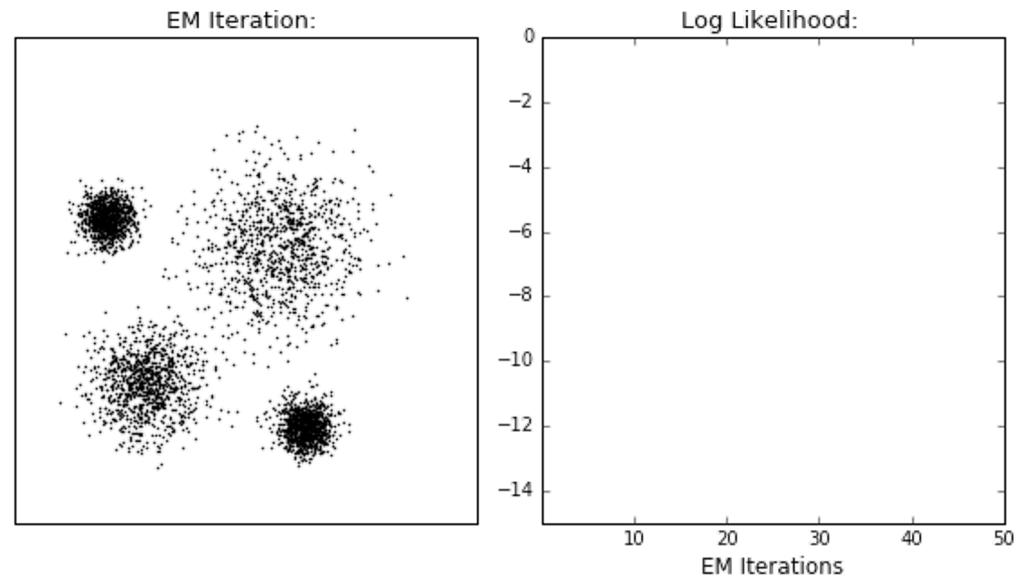
$$p_{\mathcal{M}}(x) = \sum_{i=1}^k \alpha_i \cdot p(x | \mu_i, \Sigma_i)$$

最大化对数似然

$$L = \log \prod_{j=1}^m p(x_j) = \sum_{j=1}^m \log \sum_{i=1}^k (\alpha_i \cdot p(x_j | \mu_i, \Sigma_i))$$

$$\frac{\partial L}{\partial \mu_i} = \sum_{j=1}^m \frac{\alpha_i \cdot p(x_j | \mu_i, \Sigma_i)}{\sum_{l=1}^k \alpha_l \cdot p(x_j | \mu_l, \Sigma_l)} (x_j - \mu_i) = 0 \quad \mu_i = \sum_{j=1}^m \frac{\gamma_{ji} \cdot x_j}{\sum_{j=1}^m \gamma_{ji}} \quad \Sigma_i = \sum_{j=1}^m \frac{\gamma_{ji} (x_j - \mu_i)(x_j - \mu_i)^T}{\sum_{j=1}^m \gamma_{ji}}$$

$$L + \lambda \left( \sum_{i=1}^k \alpha_i - 1 \right) \quad \sum_{j=1}^m \frac{\alpha_i \cdot p(x_j | \mu_i, \Sigma_i)}{\sum_{l=1}^k \alpha_l \cdot p(x_j | \mu_l, \Sigma_l)} + \lambda = 0 \quad \alpha_i = \frac{1}{m} \sum_{j=1}^m \gamma_{ji}$$

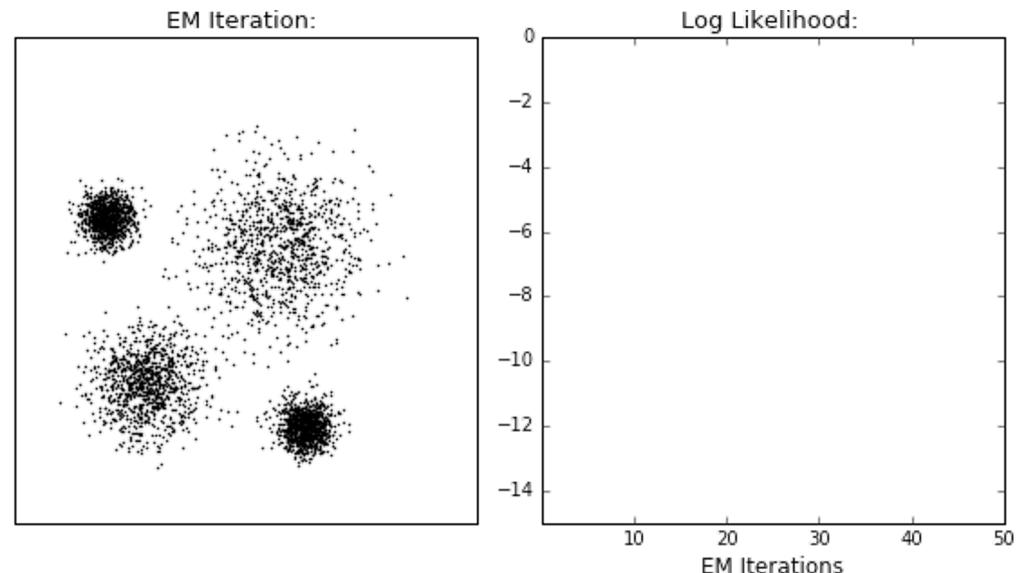


# 聚类

## 高斯混合模型

Gaussian mixture model (GMM)

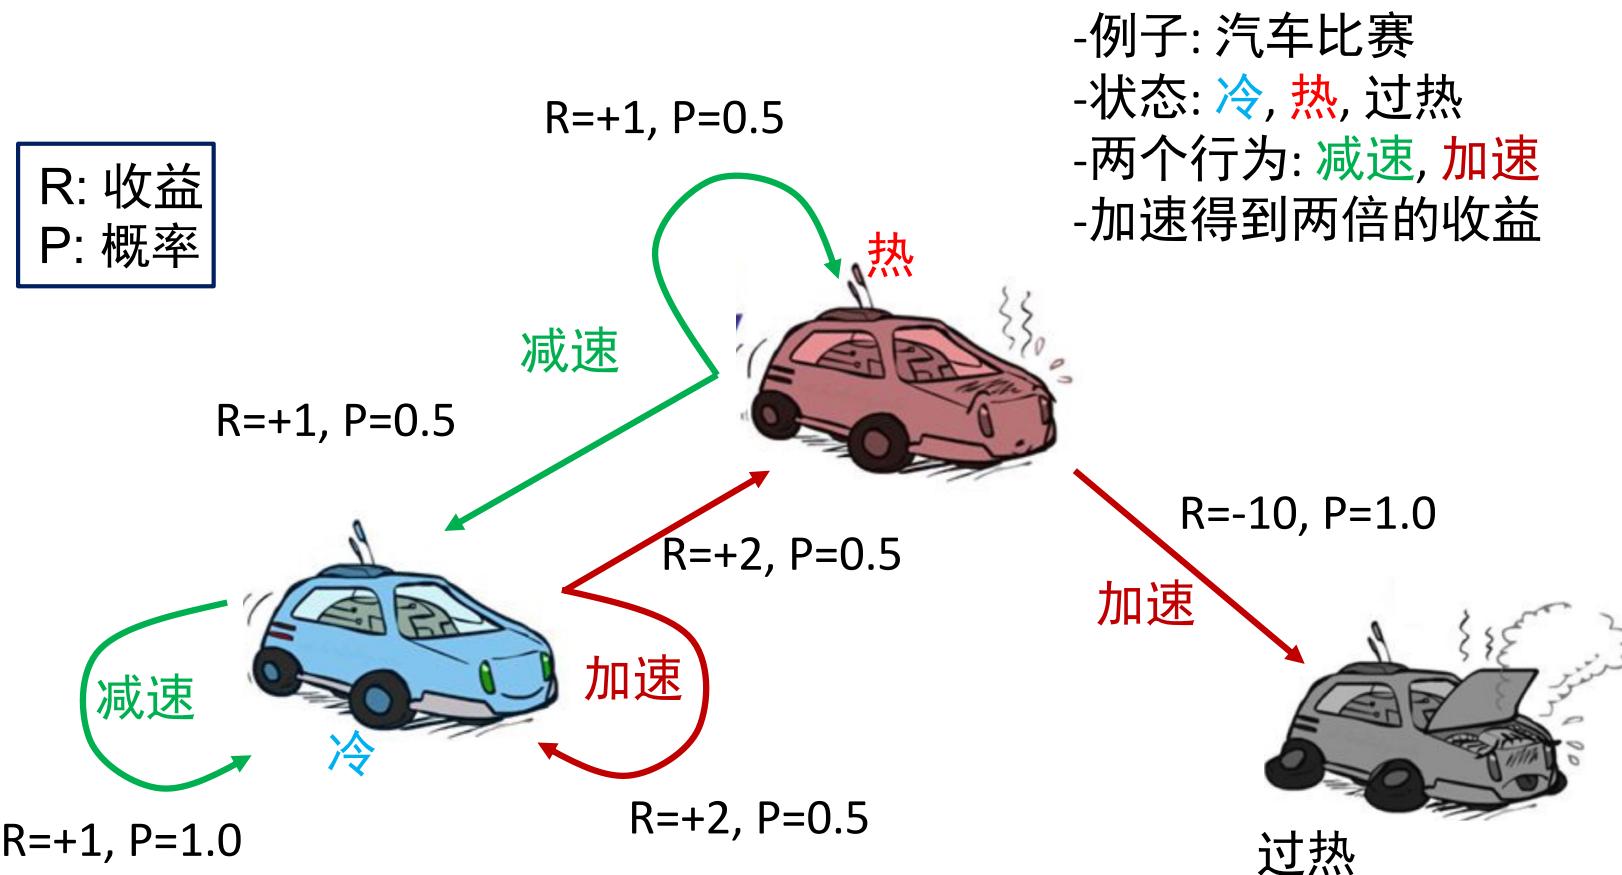
$$p_{\mathcal{M}}(x) = \sum_{i=1}^k \alpha_i \cdot p(x | \mu_i, \Sigma_i)$$



1. 选择簇的数量（与K-Means类似）并随机初始化每个簇的高斯分布参数（均值和方差）。
2. 给定每个簇的高斯分布，计算每个数据点属于每个簇的概率。  
一个点越靠近高斯分布的中心就越可能属于该簇。  
$$\frac{\alpha_i \cdot p(x_j | \mu_i, \Sigma_i)}{\sum_{l=1}^k \alpha_l \cdot p(x_j | \mu_l, \Sigma_l)}$$
3. 根据均值，协方差的定义以及2步求出的后验概率，更新均值向量，协方差矩阵式，和混合系数；  
$$\Sigma_i = \sum_{j=1}^m \frac{\gamma_{ji}(x_j - \mu_i)(x_j - \mu_i)^T}{\sum_{j=1}^m \gamma_{ji}}$$
      
$$\mu_i = \sum_{j=1}^m \frac{\gamma_{ji} \cdot x_j}{\sum_{j=1}^m \gamma_{ji}}$$
      
$$\alpha_i = \frac{1}{m} \sum_{j=1}^m \gamma_{ji}$$
4. 重复迭代2和3直到在迭代中的变化不大。
5. 对于每一个样本点，根据贝叶斯定理计算出其属于每一个簇的后验概率，并将样本划分到后验概率最大的簇上去

# 强化学习

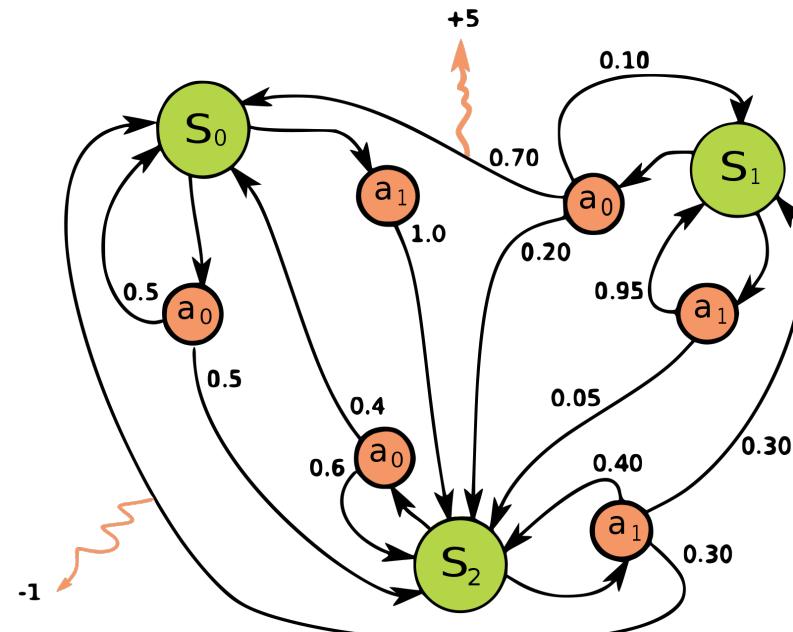
- 函数:  $f(\text{状态}, \text{行动}) \rightarrow \text{反馈值 Reward Value}$
- 基本的强化学习模拟马尔科夫决策过程.



# 传统强化学习

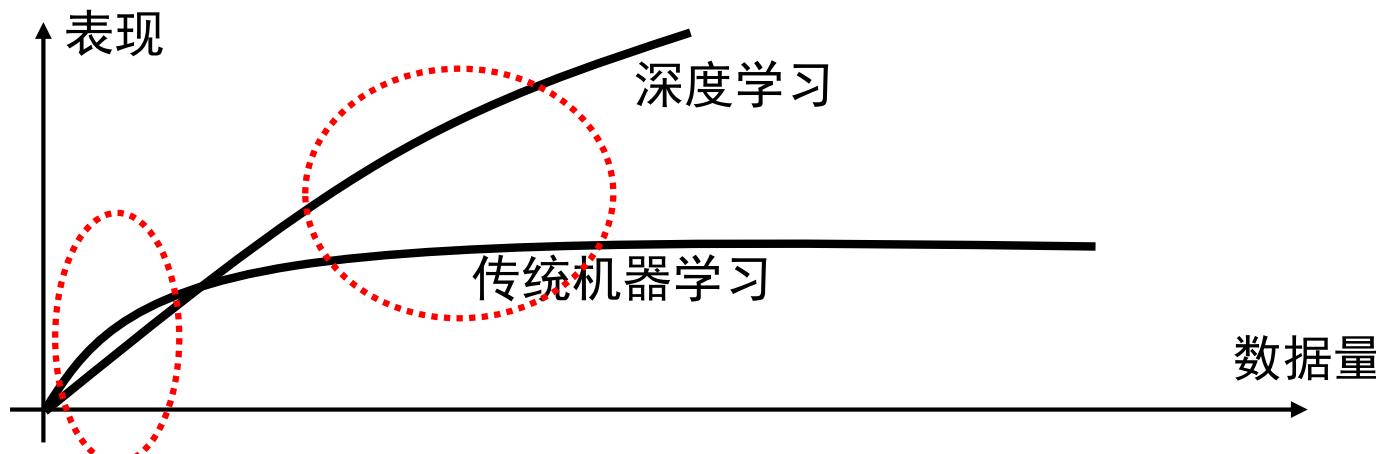
- 马尔科夫决策过程

- 从环境中不断尝试学到一个策略；根据这个策略，在状态 $x$ 下，我们能够知道下一步要执行的动作。
  - 目标是选择一个策略使得随机奖励的累积最大。
- 
- $$-\sum_{t=0}^{\infty} \gamma^t R_{at}(S_t, S_{t+1})$$



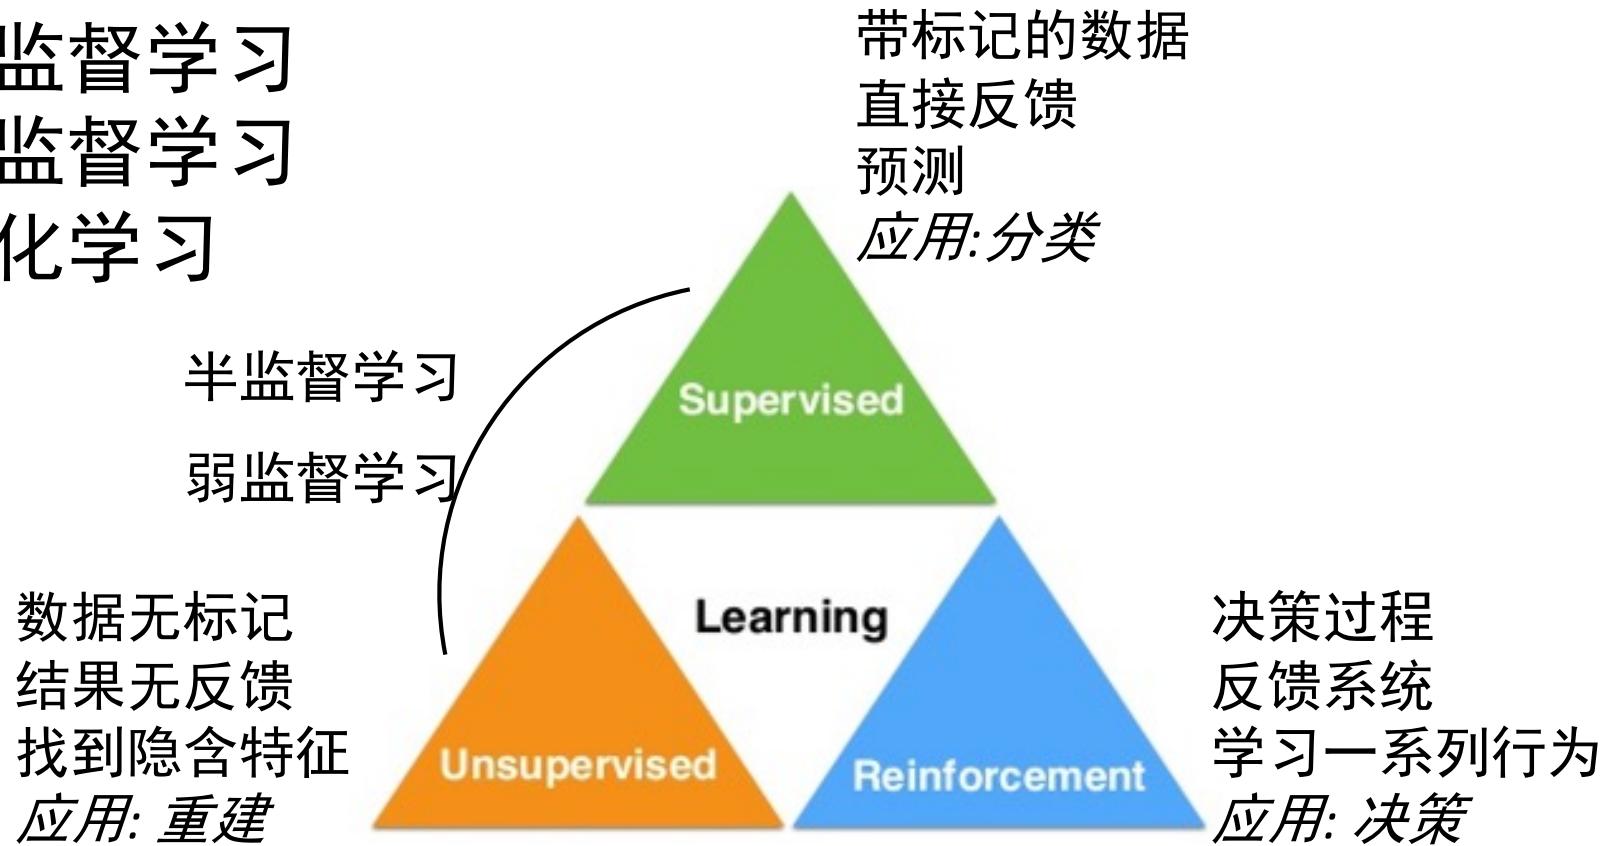
# 为什么需要深度神经网络

- 在现实世界。
  - 输入数据是高维的
  - 映射函数复杂
  - 传统方法通常会失败
- 深度神经网络能够拟合高度复杂的功能。



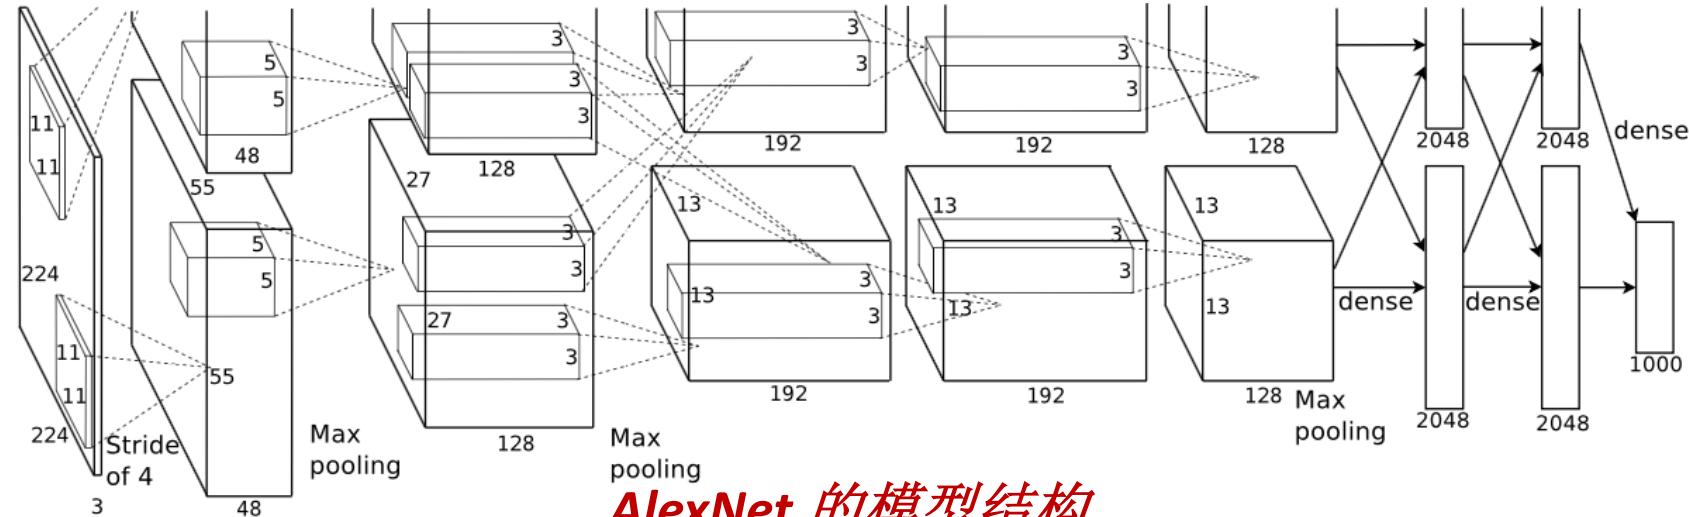
# 学习模式

- 监督学习
- 半监督学习
- 无监督学习
- 强化学习



# 卷积神经网络

## 图像分类



Model	Top-1 Error	Top-5 Error
Sparse coding	47.10%	28.20%
SIFT + FVs	45.70%	25.70%
AlexNet	37.50%	17.00%

性能对比



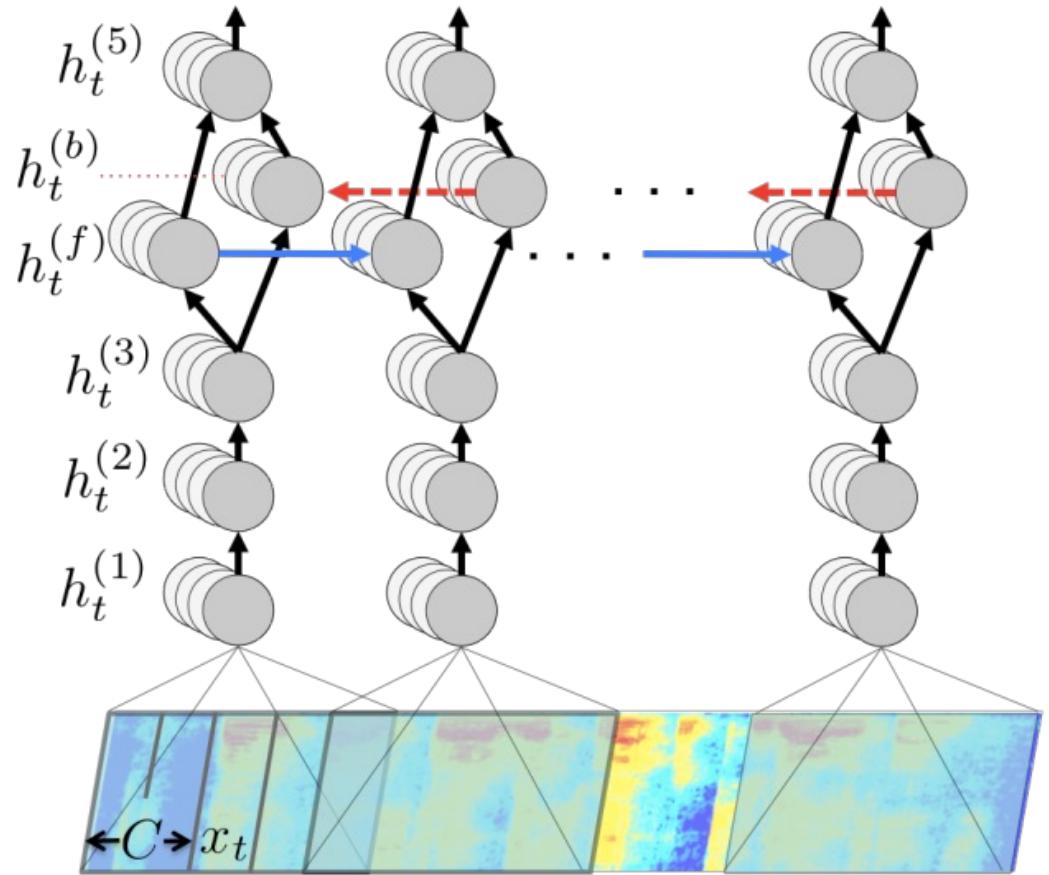
ImageNet 样本测试结果



# 监督学习



图像分类  
**CNN**



语音识别  
**RNN**



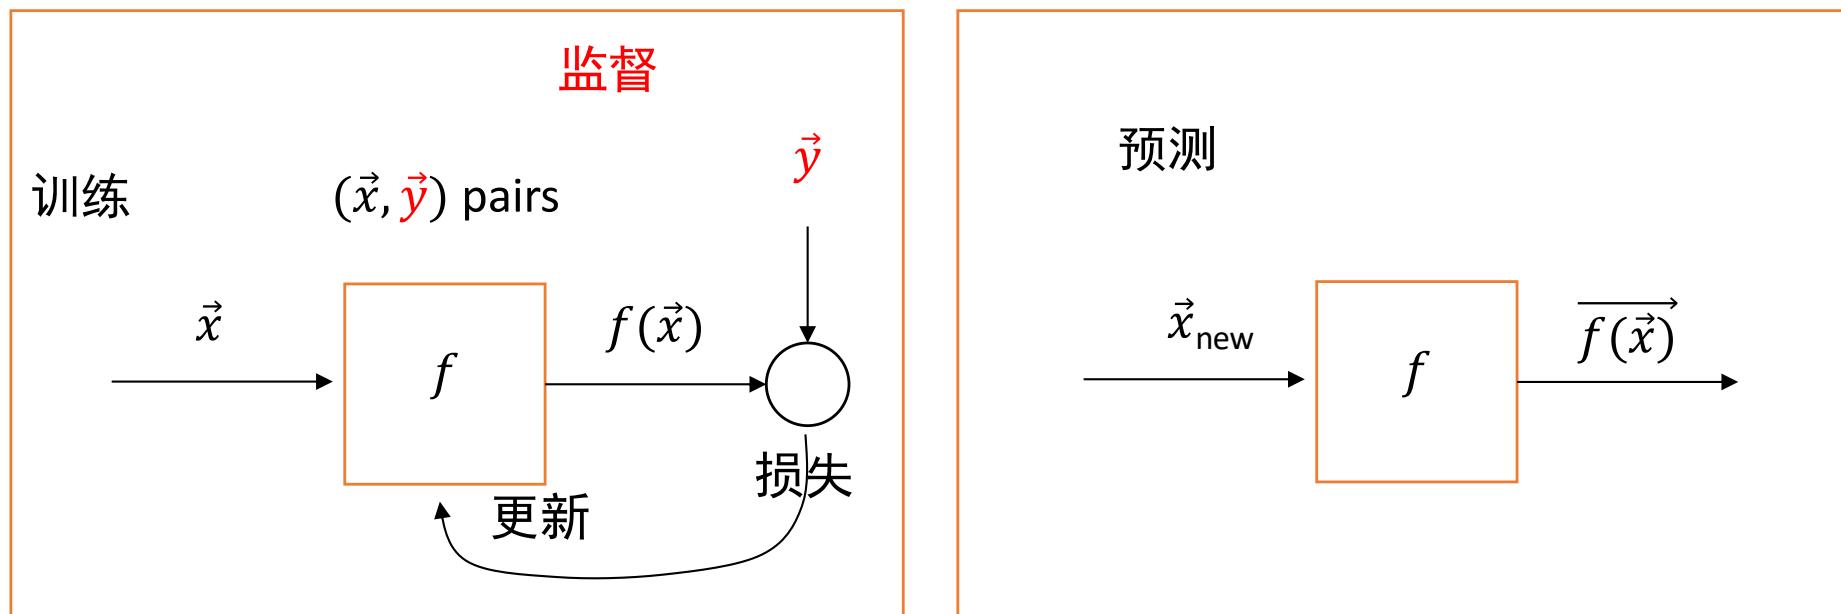
# 与传统机器学习方法相比

- 卷积神经网络
  - 在图像识别任务中
  - 传统机器学习方法，SIFT的最好结果：26.2%错误率.
  - ResNet-152：3.57%错误率.
  - 人类：5%错误率.
- 结构化学习
  - 传统机器学习方法无法解决大部分的问题.

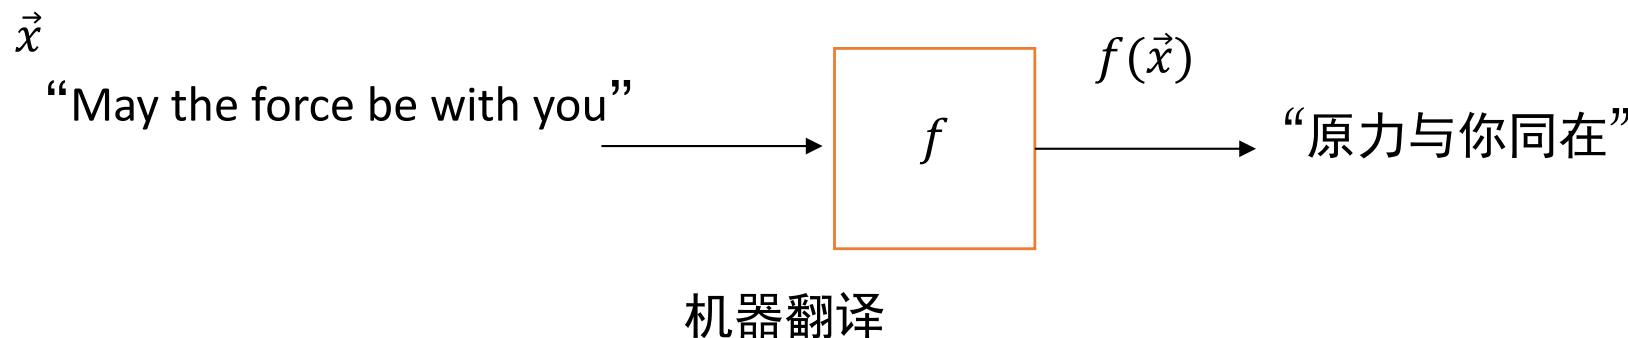
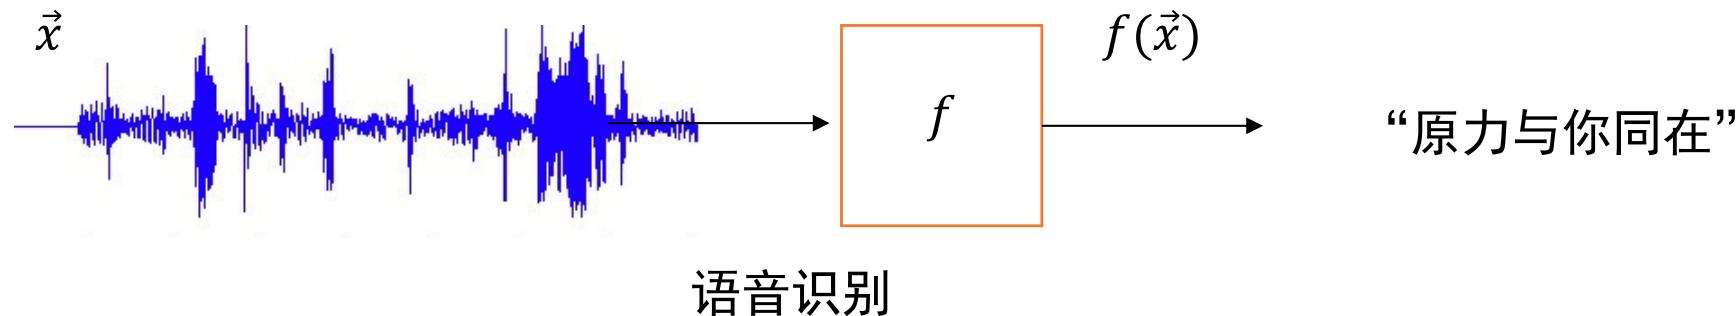


# 结构化学习

- 与回归和分类相似。
- 不同在于标签和输出都是结构化数据。
  - 比如：图片，声音，文字...



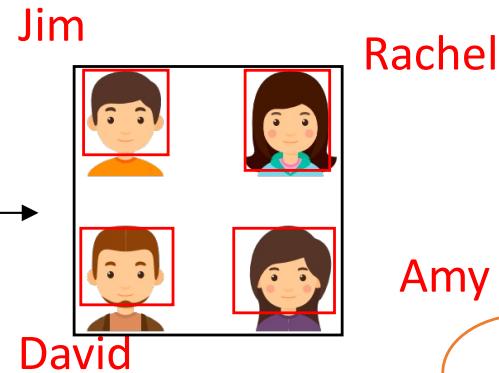
# 结构化学习



# 结构化学习

 $\vec{x}$ 

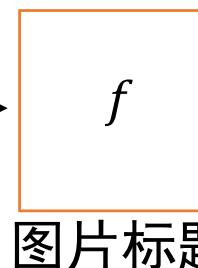
面部识别

 $f(\vec{x})$  $f$ Jim  
Rachel  
David  
Amy $\vec{x}$ 

分类

 $f(\vec{x})$ 

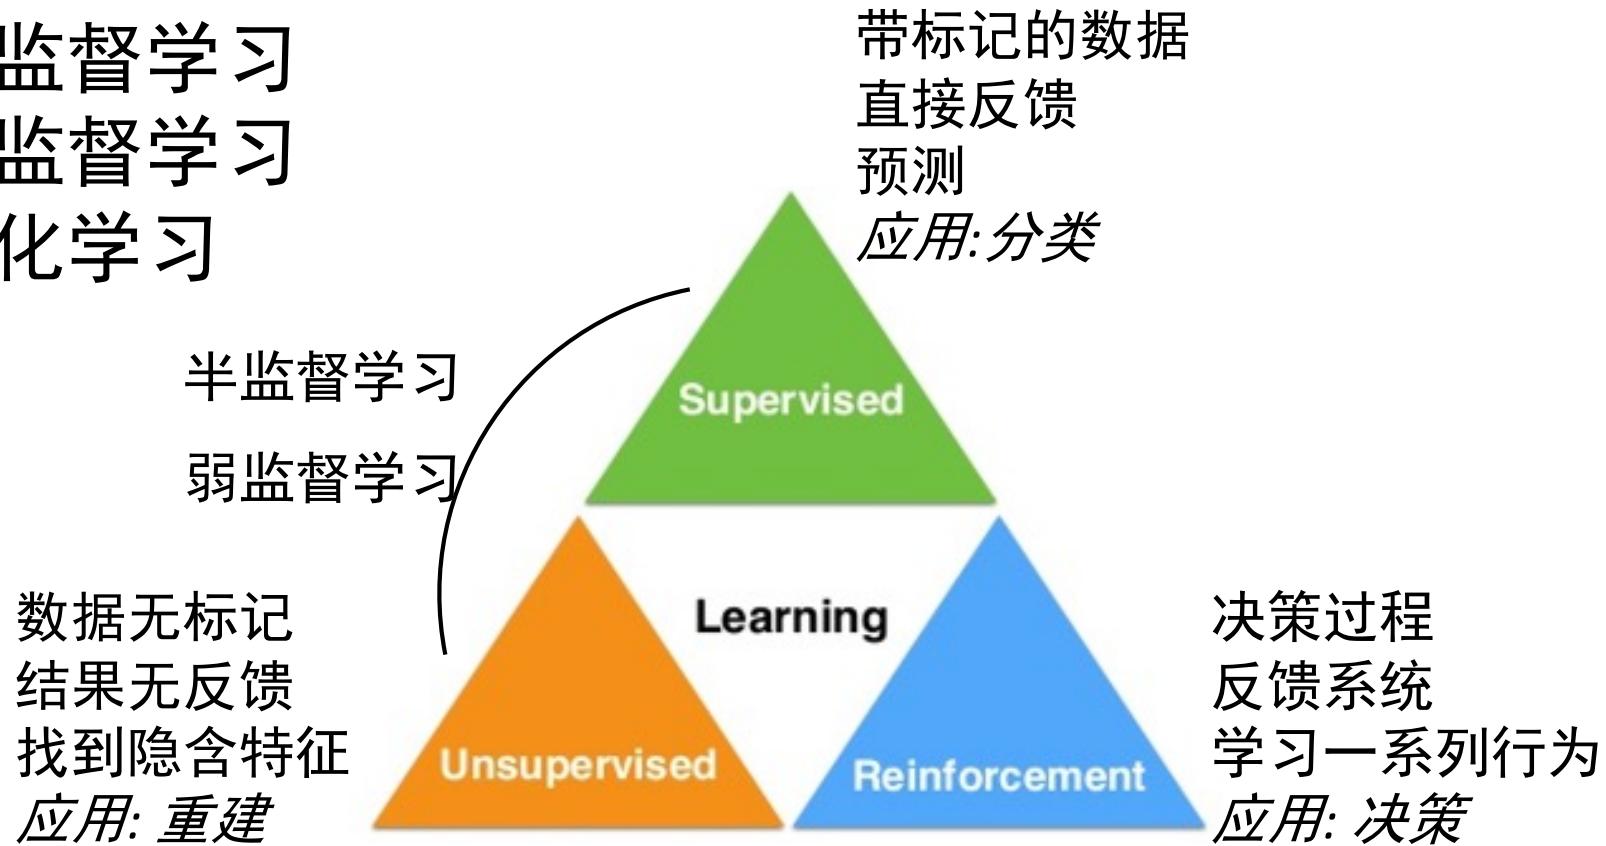
狗



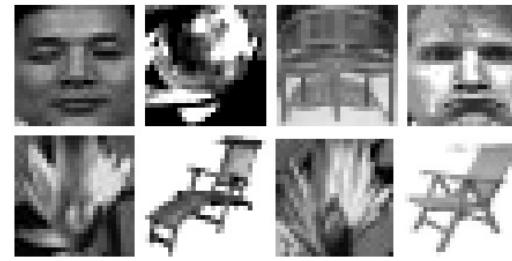
图片标题

# 学习模式

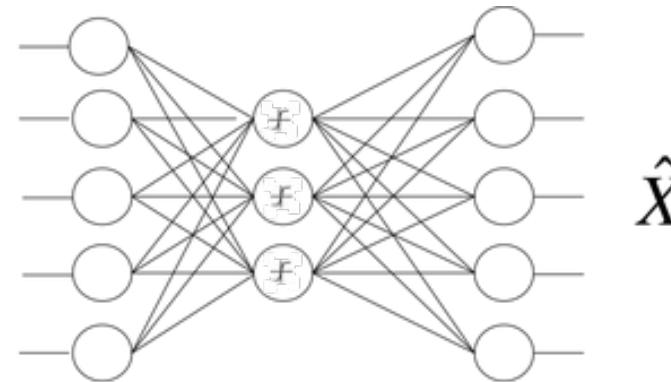
- 监督学习
- 半监督学习
- 无监督学习
- 强化学习



# 非监督学习



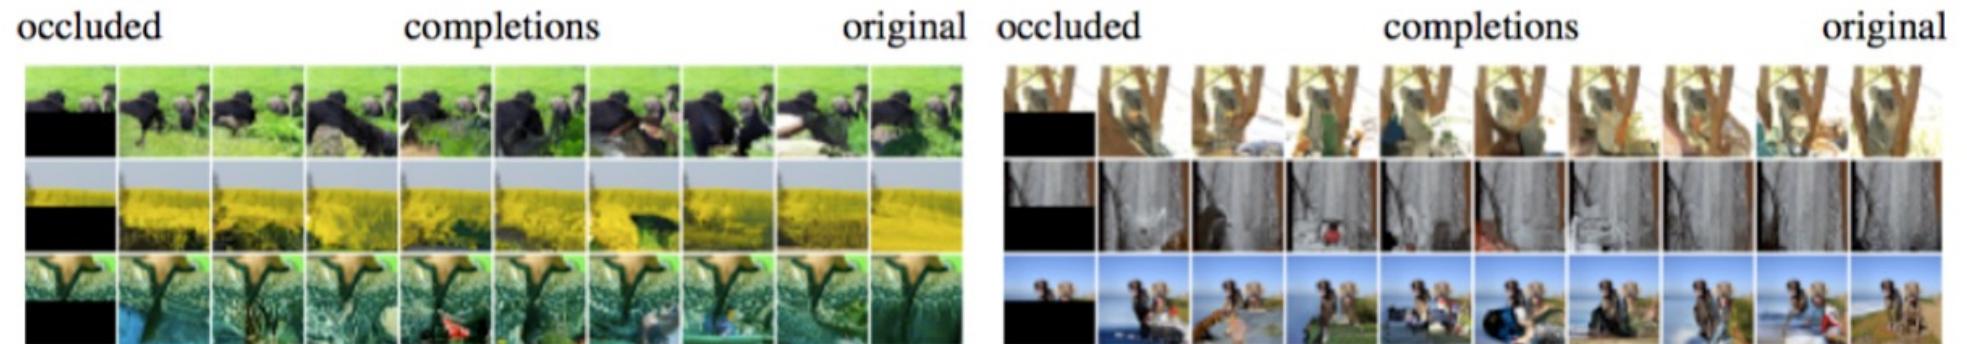
$X$



$\hat{X}$



生成模型



*Pixel RNN*



# 非监督学习的深度学习模型

- 生成式模型: 通过创造进行学习

- 自动编码机 (Autoencoder, AE)
- 可变自动编码器(Variational AE, VAE)
- 生成对抗网络(GAN)

- 自回归 : 通过预测进行创造

- OpenAI's GPT-2, 非常巨大的语言模型
- GPT-3

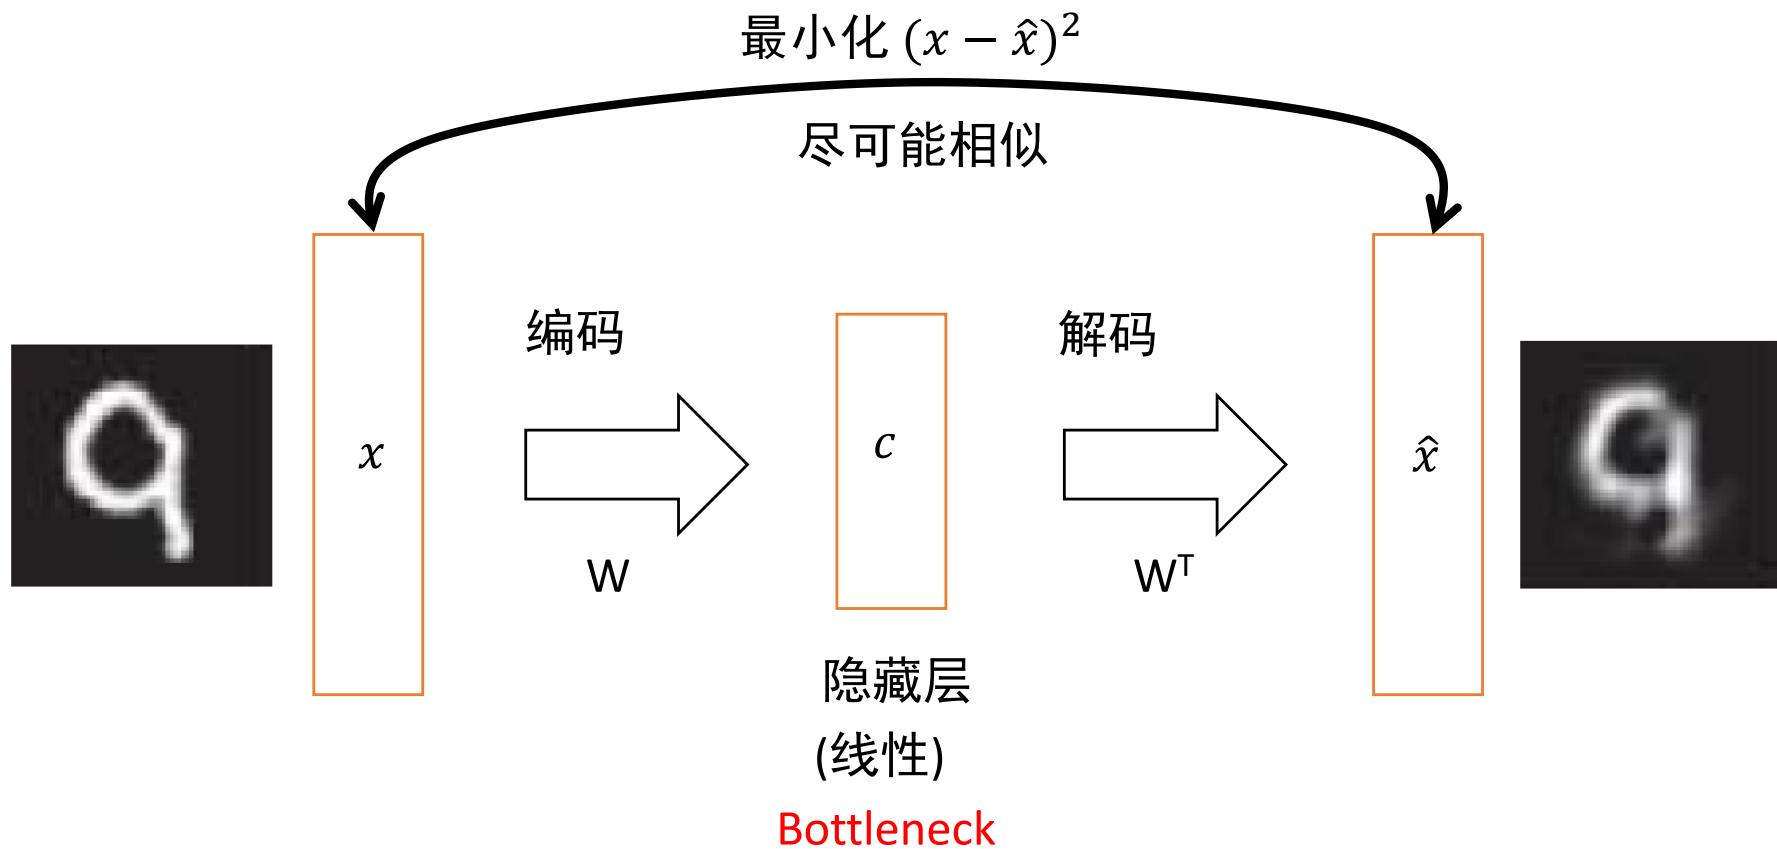
*what I cannot create, I do not understand.*

--- Richard Feynman, 理查德·费曼

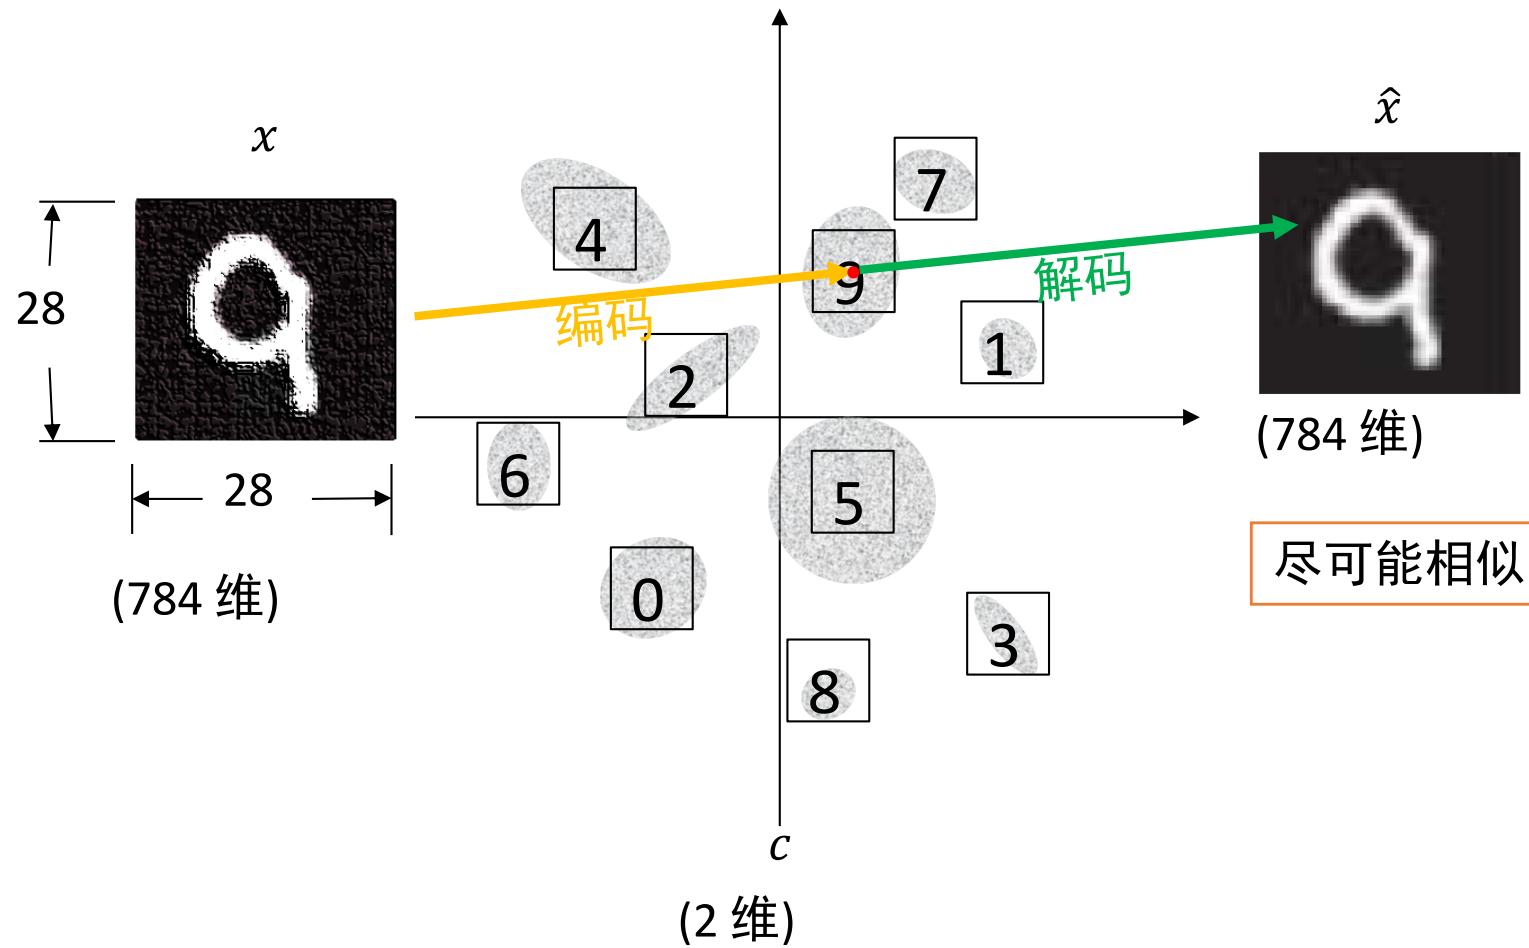


# 自动编码器

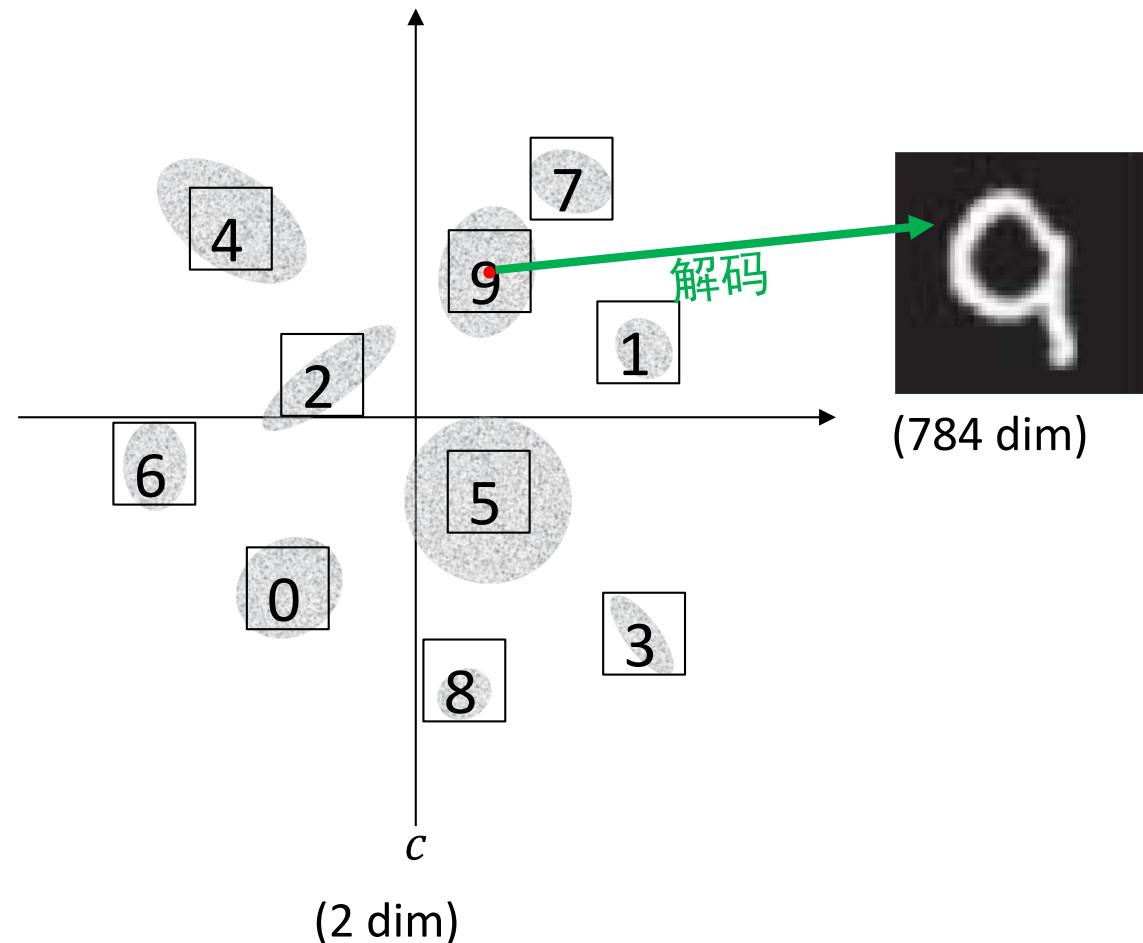
- 自动编码器
  - 深度神经网络来编码和解码



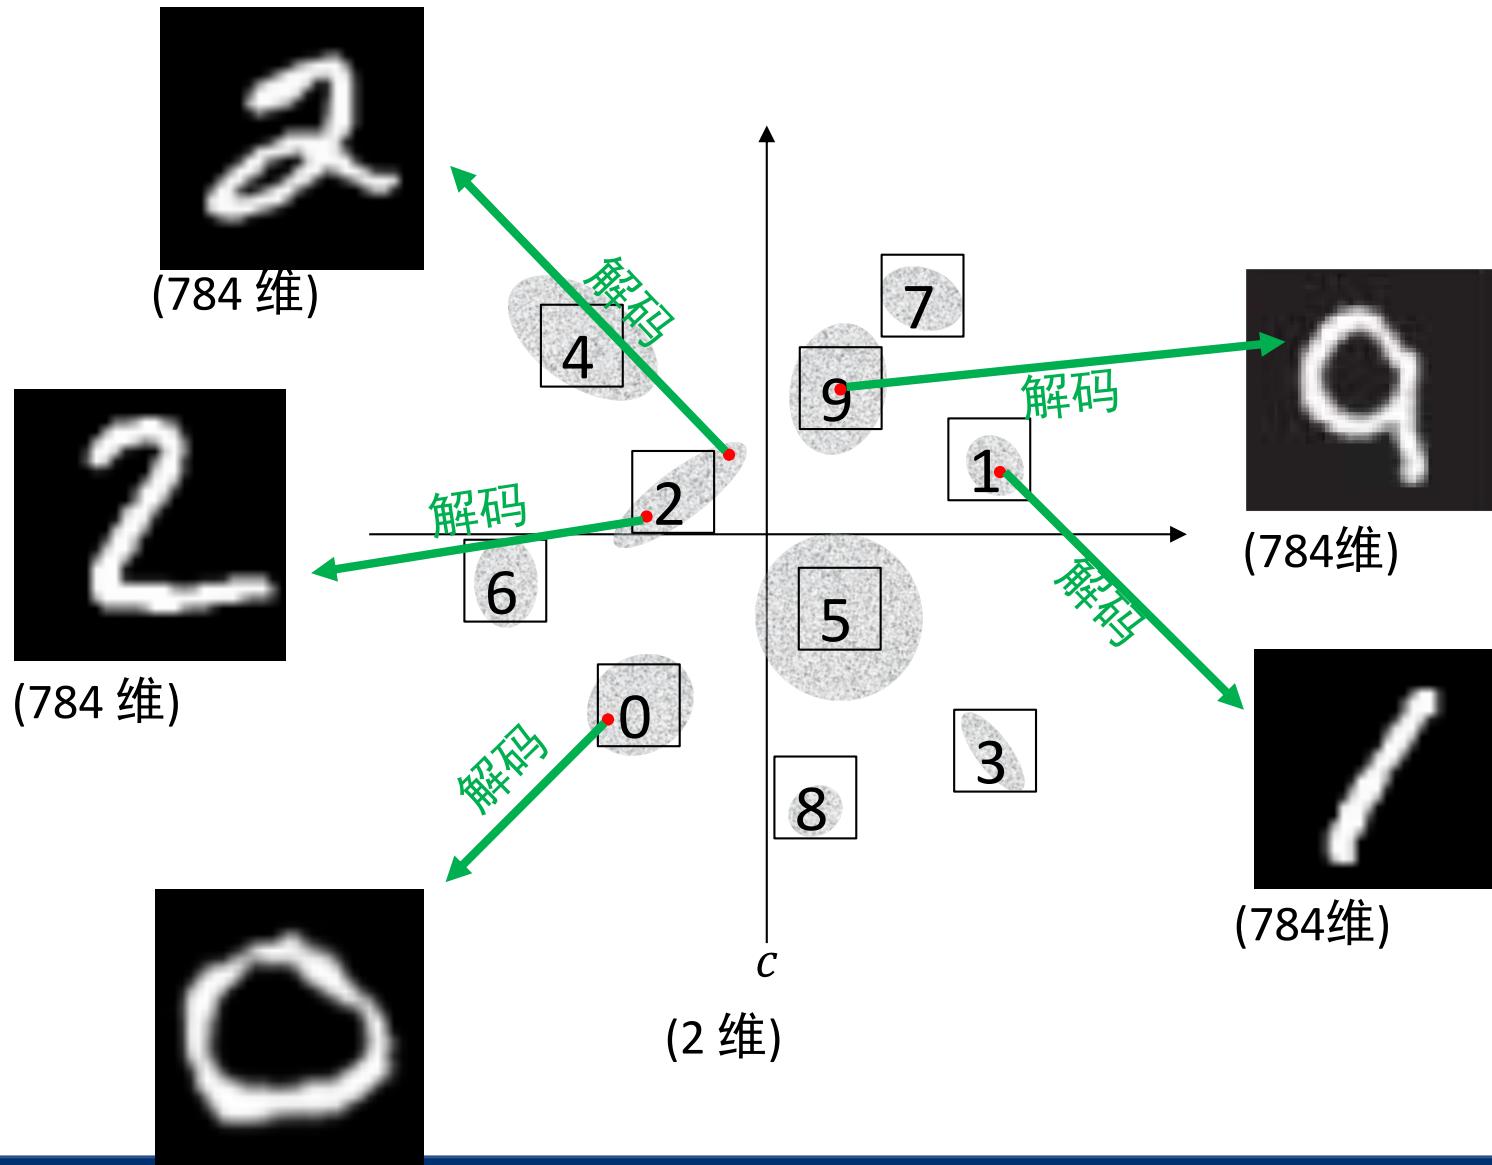
# 自动编码器



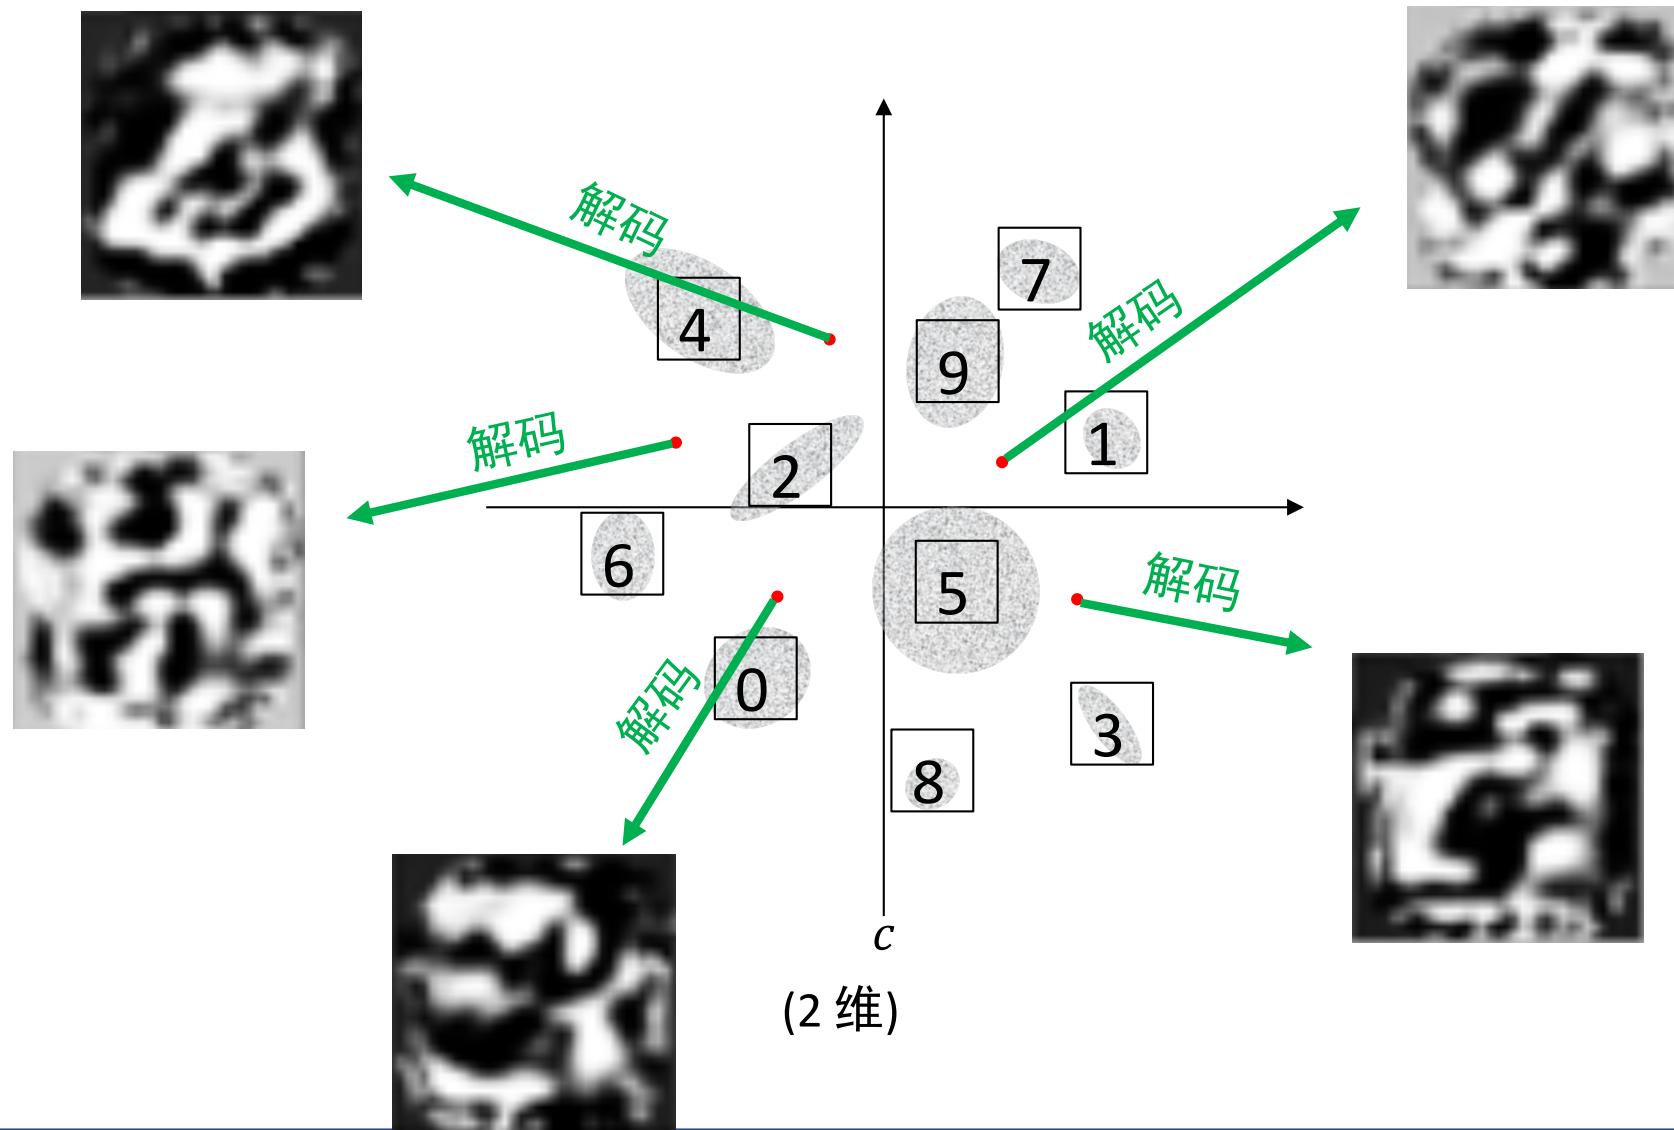
# 自动编码器



# 自动编码器能做

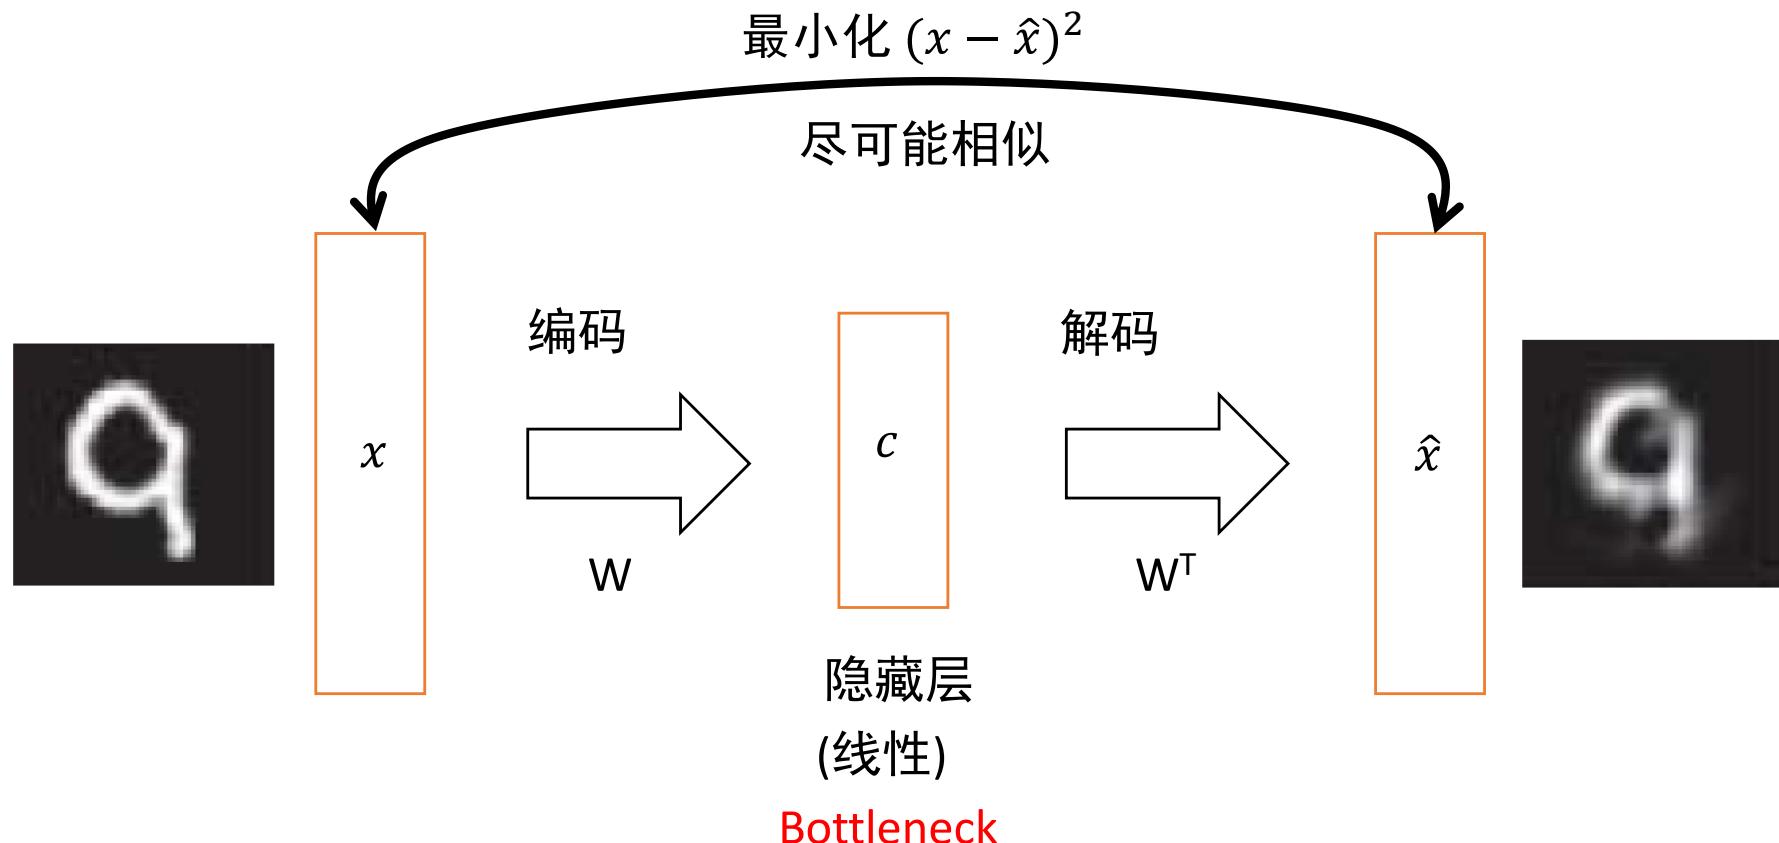


# 自动编码器不能做

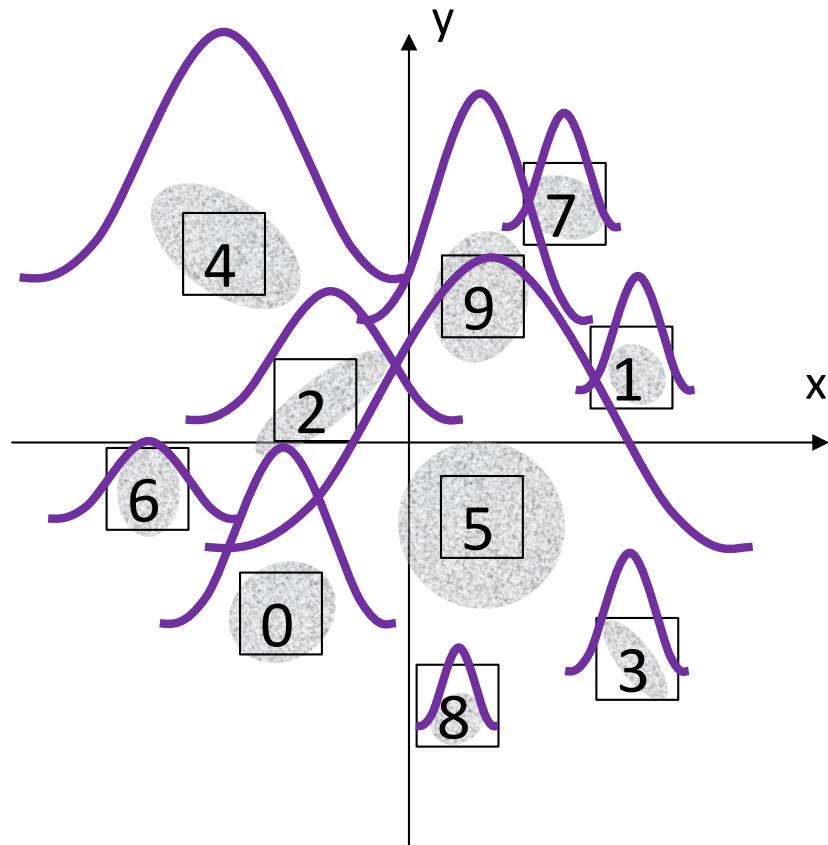


# 自动编码器不能用来创造

- 我们仅要求AE使原始数据更接近重建数据。
- 我们从不告诉算法在两个类别中间的数据该怎么办。



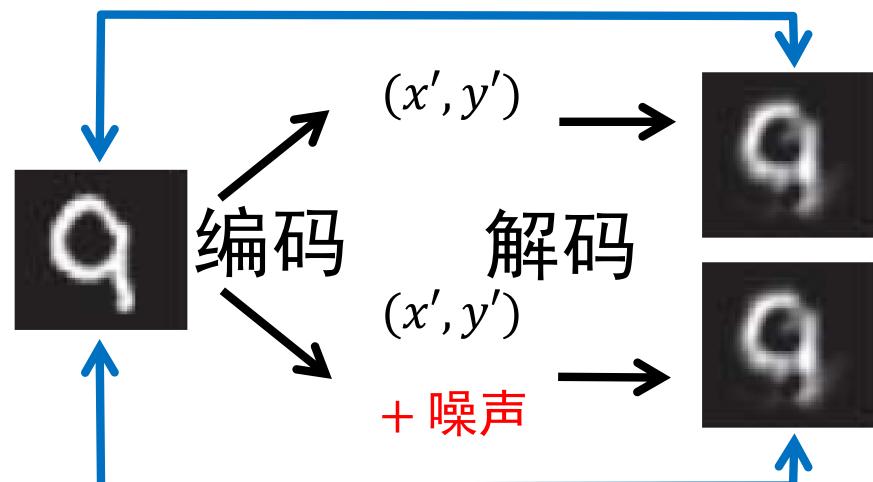
# 那怎么改进? —可变自动编码器.



(高斯分布是一个很好的噪声选择.)

我们将每个原始数据点添加一些“噪声”到其附近的其他空间，并希望用概率填充整个空间

- 不仅使这两个保持接近



但仍使这两个保持接近



# VAE的结果



现在：

两个数字之间的数据点看起来像数字了。

面部表情看起来不错，但是还不够现真实。



# 自回归，通过预测进行创造。

- 数据分为一系列小片段，每个小片段依次预测。
- 通过连续猜测接下来会发生什么，将猜测作为输入并再次进行猜测，可以使用此类模型来生成数据。
- OpenAI's GPT-2
  - 给它一个人为的书面开始，它将一直持续下去。人们可以用它来写新颖的故事，制作假新闻，...

但是这非常危险



程序员拯救乐坛？OpenAI用“逆天”GPT2.0搞了个AI音乐生成器

**逆天的语言AI模型来了！编故事以假乱真，问答翻译写摘要都行，横扫各大语言建模任务**

## 逆天的GPT-2居然还能写代码

OpenAI研究实验室已经发布了一套AI系统的完整版本，它用于自动生成文本，但是专家警告称该系统可能被用于恶意目的。该机构最初于今年2月发布了GPT-2程序，但由于担心该程序的完整版本会被用于传播假新闻，垃圾邮件和虚假信息，因此拒绝公布该程序的完整版本。



# Artificial Intelligence Generated Content (AIGC)



ChatGPT是继Alpha Go后又一里程碑事件，据市场调查机构Gartner预测，2030年以人机交互为代表的AIGC市场规模将超过万亿人民币。

AI艺术工具Midjourney创作的图像

75

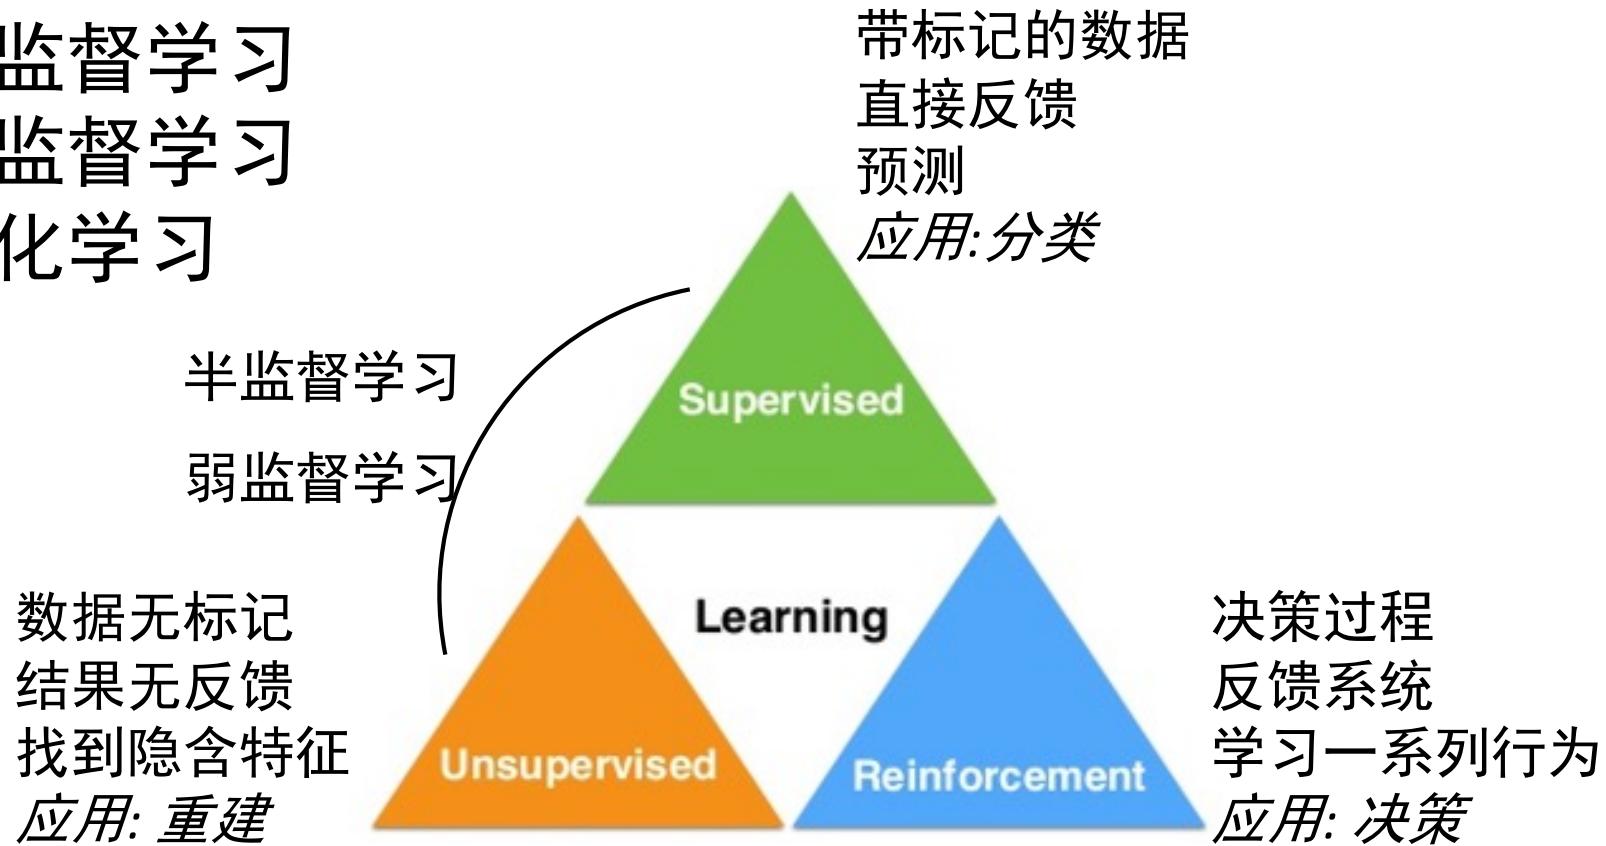
你会让哪些人类职业消失？



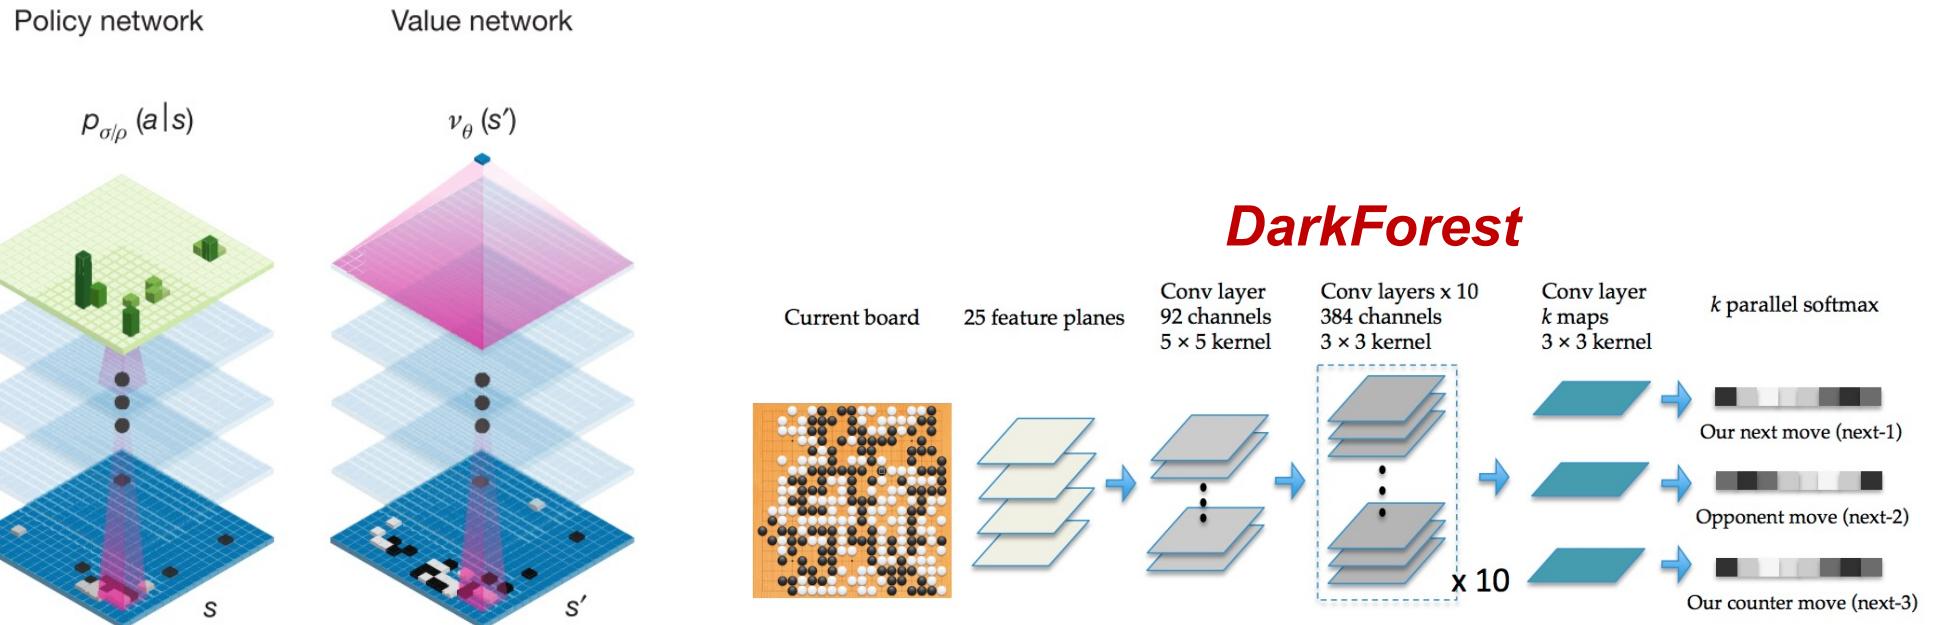
随着人工智能和机器学习技术的发展，一些重复性和高度规范化的工作，如数据输入，记账和统计，以及一些简单的客户服务工作，可能会被自动化和机器人取代。然而，这不一定意味着这些工作完全消失，也不意味着不需要人类干预或监督。实际上，人工智能可以为人类工作者创造新的机会，例如更高级别的分析和决策工作。另外，技术的发展可能会带来新的工作岗位，并补充那些被自动化取代的工作。

# 学习模式

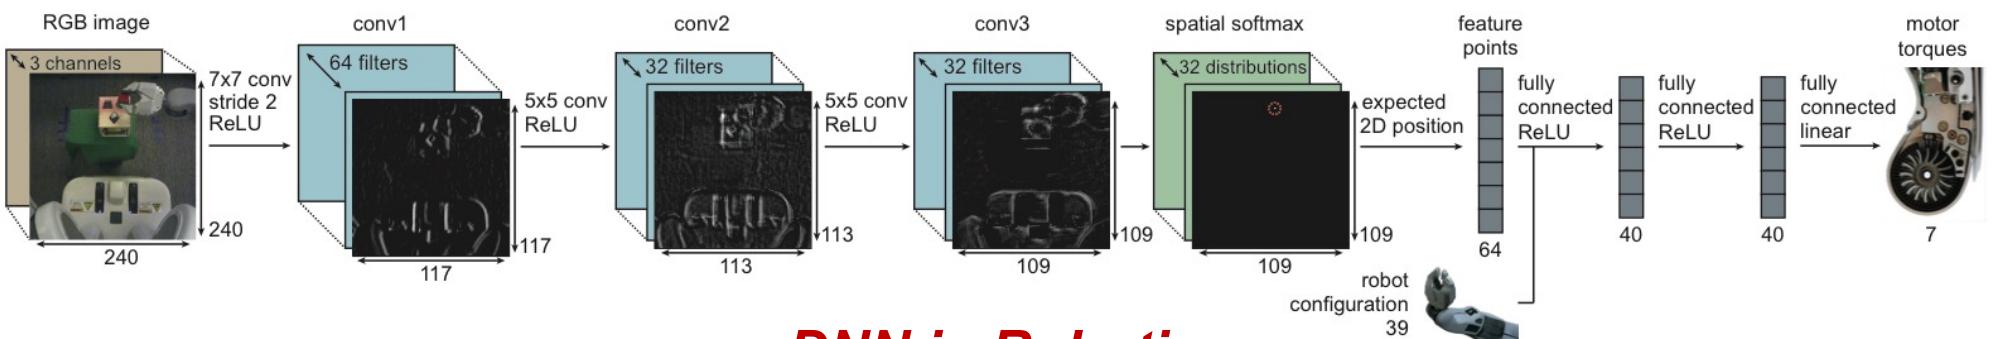
- 监督学习
- 半监督学习
- 无监督学习
- 强化学习



# 强化学习



## Alpha Go



## DNN in Robotics

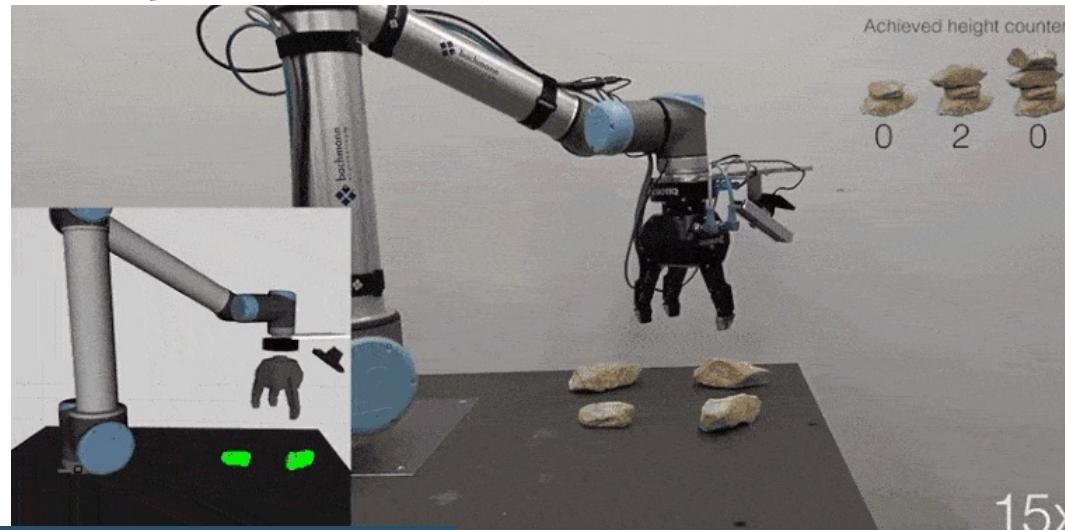


D. Silver et al. Mastering the Game of Go with Deep Neural Networks and Tree Search. *Nature*, 2016.

T. Yuandong, Z. Yan. Better Computer Go Player with Neural Network and Long-term Prediction. arXiv preprint arXiv:1511.06410.

Levine, Sergey, et al. "End-to-end training of deep visuomotor policies." arXiv preprint arXiv:1504.00702.

# 深度强化学习的一些例子



# DeepMind 跑酷小人



# Donkey Car trained with Double Deep Q Learning (DDQN)

# 这节课，我们学习了

- 传统机器学习算法的简单回顾.
  - 监督/无监督/强化学习
- 为什么需要深度学习
  - 现实世界: 数据维度高, 映射关系非常复杂.
  - 深度学习有这个能力去拟合.
- 深度学习的例子
  - 监督学习: 卷积神经网络、结构化学习
  - 非监督学习: 自动编码器、可变自动编码器、GAN、GPT-2
  - 深度强化学习

